## Streaming de Dados em Tempo Real: Aula 2

Prof. Felipe Timbó



## Ementa (dia 2)

- Data Ingestion com Apache Kafka
- Kafka Web Project

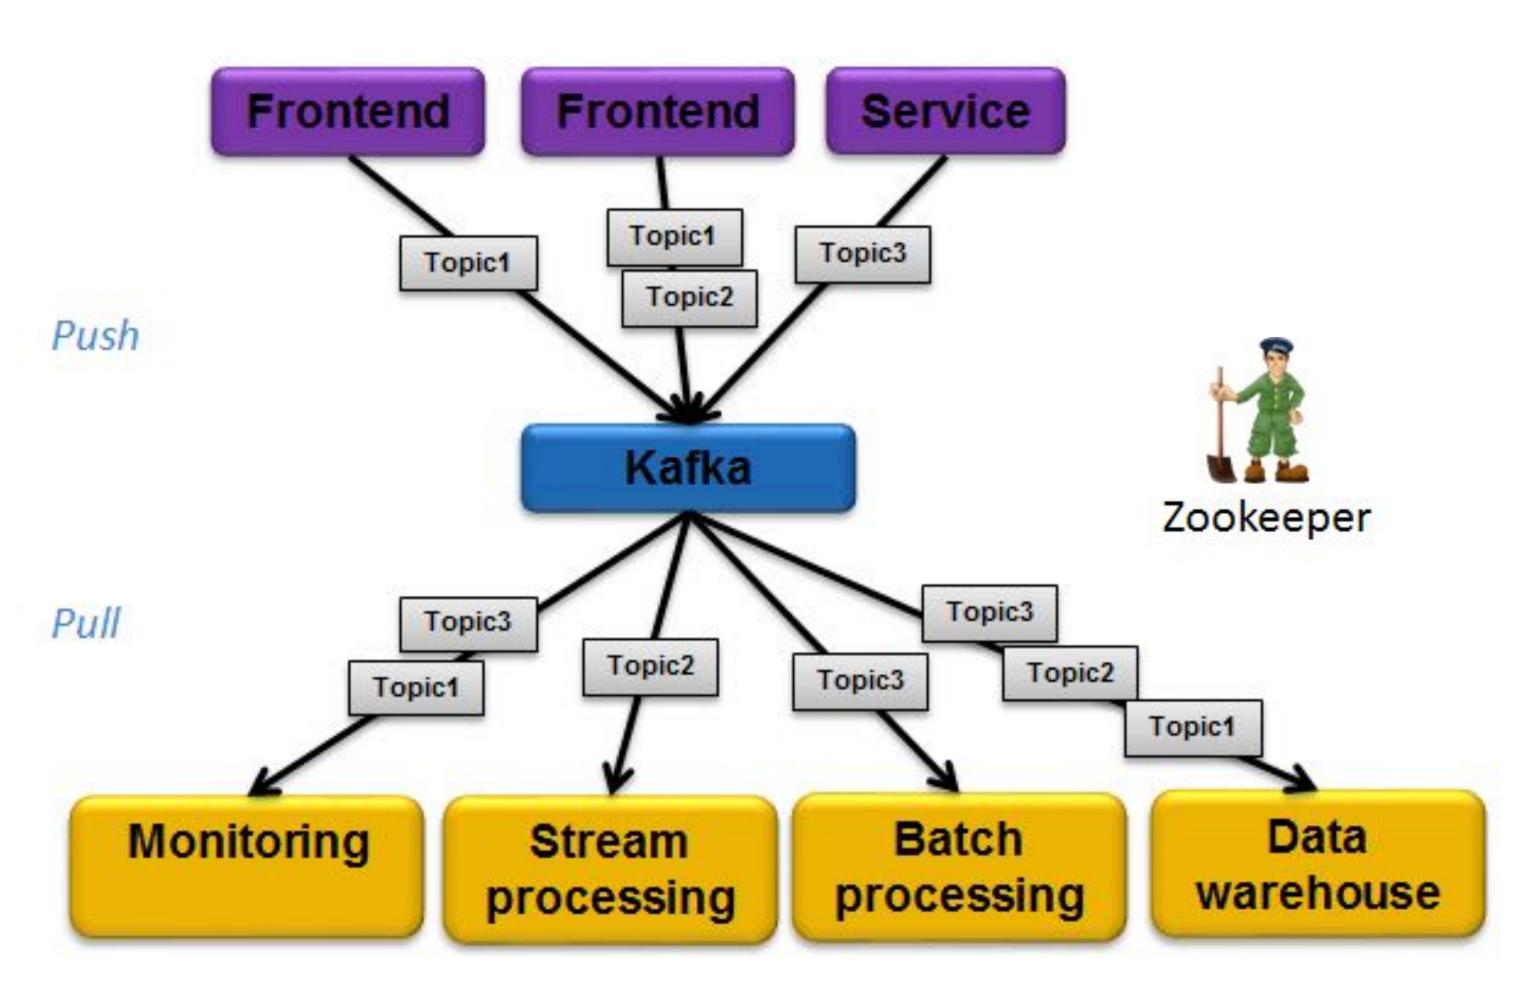
# Apache Kafka (cont.)

#### Kafka: relembrando

**Producers** 

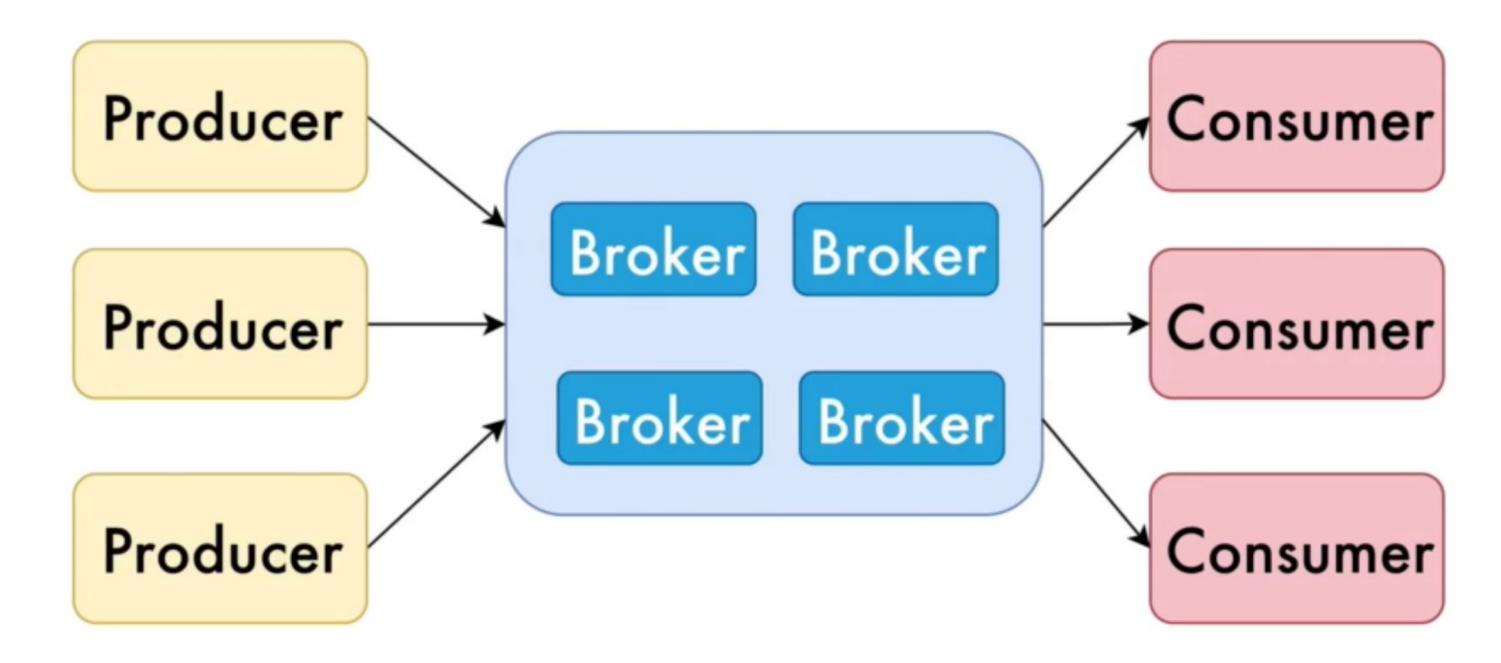
Broker

Consumers



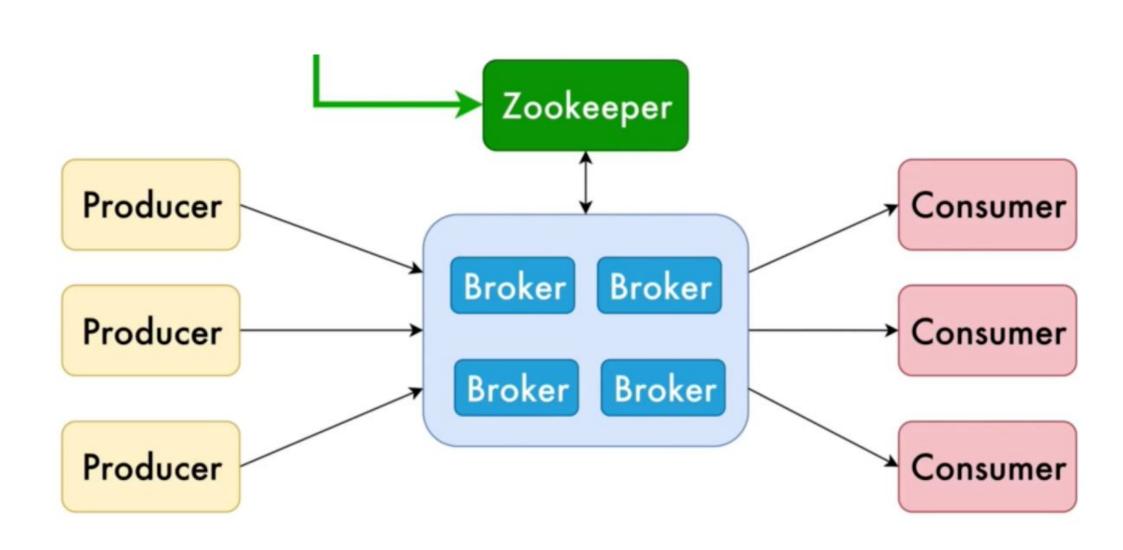
#### Kafka na vida real

- Em aplicações do mundo real: LinkedIn, Netflix:
  - Aplicações distribuídas, isto é, mais de um Broker



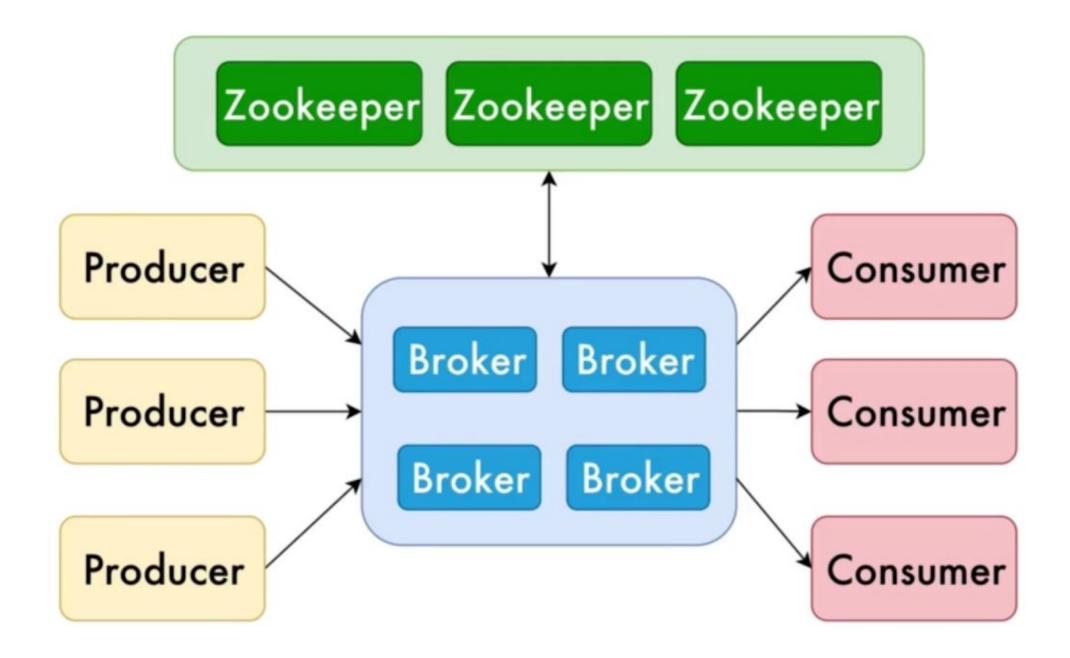
## Zookeeper

- Utilizado não só pelo Apache Kafka, mas pelo Apache Hadoop também, por exemplo.
- Mantém uma lista de brokers ativos
- Elege controller
- Gerencia as configurações de tópicos e partições.



## Zookeeper na vida real

• Múltiplos zookeepers rodando, para garantir a tolerância a falhas e os benefícios dos sistemas distribuídos.



#### Instalando o Apache Kafka

#### Realizar o download do Apache Kafka:

```
> curl
http://ftp.unicamp.br/pub/apache/kafka/2.8.1/ka
fka 2.12-2.8.1.tgz -o ~/Downloads/kafka.tgz
```

```
% Total % Received % Xferd Average Speed Time Time Current
Dload Upload Total Spent Left Speed
100 62.6M 100 62.6M 0 0 528k 0 0:02:01 0:02:01 --:-- 345k
posgrad@posgrad-vm:~$
```

#### Instalando o Apache Kafka

Criar um diretório chamado kafka e entrar nele:

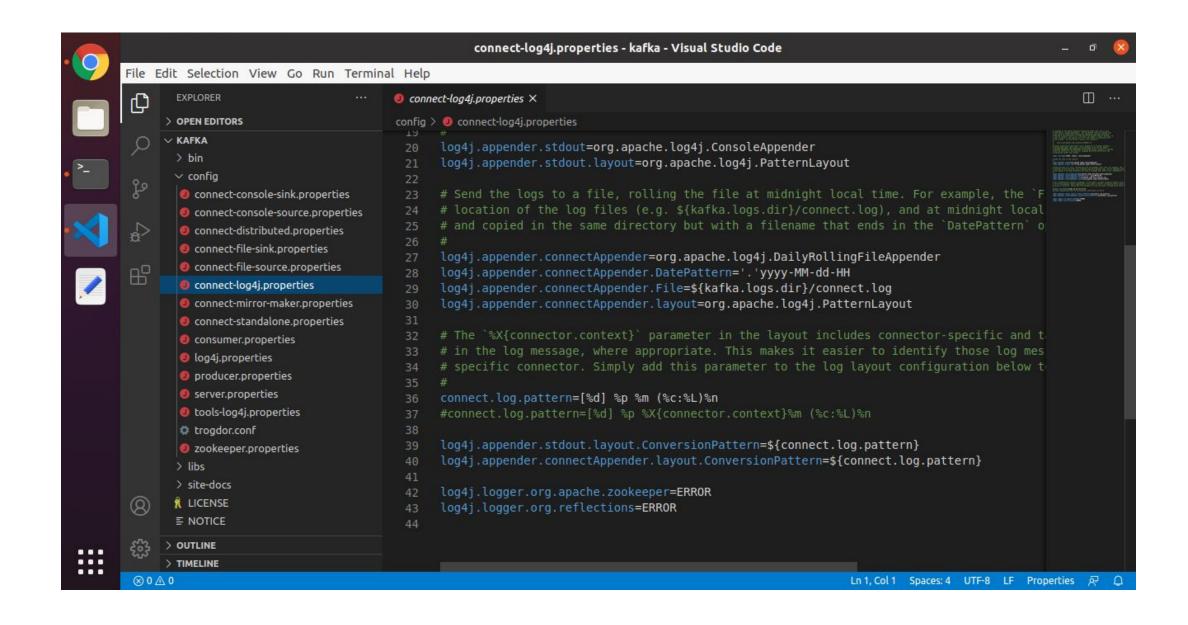
- > mkdir kafka
- > cd kafka

Extrair os arquivos que estão na pasta download para o diretório criado:

> tar -xvzf ~/Downloads/kafka.tgz --strip 1

## Visualizando os arquivos do Kafka

Abrir o VS Code
Clicar em Open Folder
Selecionar a pasta kafka



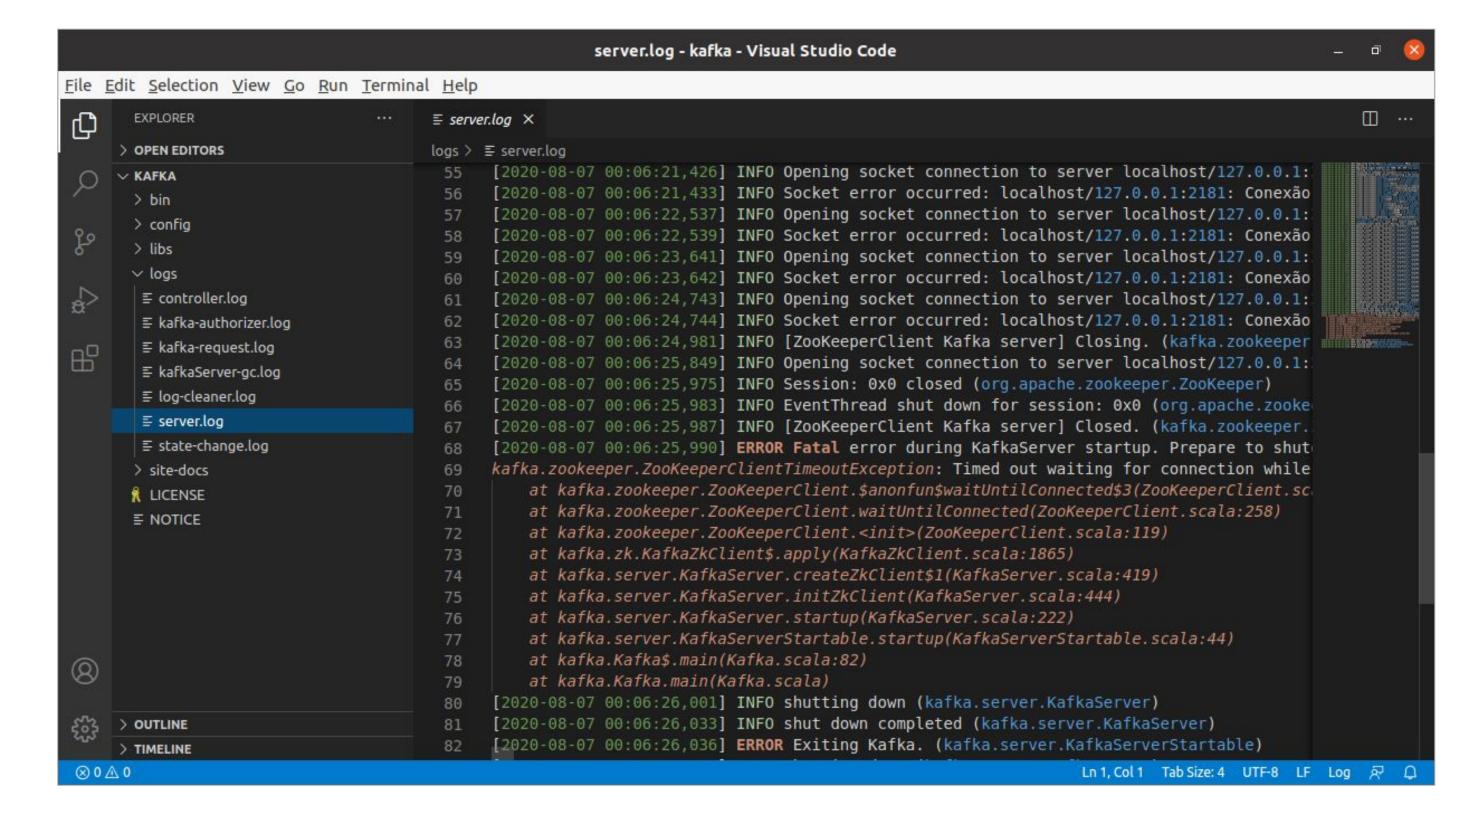
#### Inicializando o Servidor Kafka

>> bin/kafka-server-start.sh config/server.properties

```
posgrad@posgrad-vm: ~/kafka
keeper.ZooKeeperClient)
[2020-08-07 00:06:25,990] ERROR Fatal error during KafkaServer startup. Prepare
to shutdown (kafka.server.KafkaServer)
kafka.zookeeper.ZooKeeperClientTimeoutException: Timed out waiting for connectio
n while in state: CONNECTING
        at kafka.zookeeper.ZooKeeperClient.ŞanonfunŞwaitUntilConnected$3(ZooKeep
erClient.scala:262)
        at kafka.zookeeper.ZooKeeperClient.waitUntilConnected(ZooKeeperClient.sc
ala:258)
        at kafka.zookeeper.ZooKeeperClient.<init>(ZooKeeperClient.scala:119)
        at kafka.zk.KafkaZkClient$.apply(KafkaZkClient.scala:1865)
        at kafka.server.KafkaServer.createZkClient$1(KafkaServer.scala:419)
        at kafka.server.KafkaServer.initZkClient(KafkaServer.scala:444)
        at kafka.server.KafkaServer.startup(KafkaServer.scala:222)
        at kafka.server.KafkaServerStartable.startup(KafkaServerStartable.scala:
44)
        at kafka.Kafka$.main(Kafka.scala:82)
        at kafka.Kafka.main(Kafka.scala)
[2020-08-07 00:06:26,001] INFO shutting down (kafka.server.KafkaServer)
[2020-08-07 00:06:26,033] INFO shut down completed (kafka.server.KafkaServer)
[2020-08-07 00:06:26,036] ERROR Exiting Kafka. (kafka.server.KafkaServerStartabl
[2020-08-07 00:06:26,040] INFO shutting down (kafka.server.KafkaServer)
posgrad@posgrad-vm:~/kafka$
```

## Observando os logs de erro do kafka

No VS Code, abrir a pasta logs, e o arquivo server.log



## Inicializando o Zookeeper

>> bin/zookeeper-server-start.sh config/zookeeper.properties

#### Zookeeper por padrão escuta a porta 2181 Observar arquivo *zookeeper.properties* na pasta *config*

#### Inicializando o Servidor Kafka (novamente)

#### Em outro terminal

```
posgrad@posgrad-vm: ~/kafka  

posgrad@posgrad-vm: ~/kafka  

posgrad@posgrad-vm: ~/kafka  

posgrad@posgrad-vm: ~/kafka  

[2020-08-07 00:30:28,924] INFO maxSessionTimeout set to 60000 (org.apache.zookee per.server.ZooKeeperServer)
[2020-08-07 00:30:28,925] INFO Created server with tickTime 3000 minSessionTimeo ut 6000 maxSessionTimeout 60000 datadir /tmp/zookeeper/version-2 snapdir /tmp/zookeeper/version-2 (org.apache.zookeeper.server.ZooKeeperServer)
[2020-08-07 00:30:28,973] INFO Using org.apache.zookeeper.server.NIOServerCnxnFactory as server connection factory (org.apache.zookeeper.server.ServerCnxnFactory)
```

#### Inicie o Kafka novamente:

>> bin/kafka-server-start.sh config/server.properties

#### Voilà

Zookeeper localhost:2181

Kafka server (broker) localhost:9092

## Utilizando o KAFKA via CLI (Command-Line Interface)

## Criando um tópico

Em outro terminal: Terminal 1

➤ bin/kafka-topics.sh --create --bootstrap-server localhost:9092 --topic cidades

#### Listar os tópicos existentes:

➤ bin/kafka-topics.sh --list --zookeeper localhost:2181

#### Deletar os tópicos existentes:

➤ bin/kafka-topics.sh --delete --bootstrap-server localhost:9092 --topic <nome\_topico>

## Produzindo mensagens

#### Acessando o kafka broker para enviar mensagens

- ➤ bin/kafka-console-producer.sh --broker-list localhost:9092 --topic cidades
  - > Fortaleza
  - > Sobral
  - > Canindé
  - > Russas
  - > Quixadá

## Consumindo mensagens

Em outro terminal: Terminal 2

➤ bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --topic cidades

#### De volta ao Terminal 1 digitar:

- > New York
- > Dubai
- > Rio de Janeiro
- > Buenos Aires

#### Consumindo mensagens do início

Terminal 2

#### Parar o terminal 2:

> ctrl+c

#### Executar novamente para obter mensagens desde o início:

➤ bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --topic cidades --from-beginning

## Fatos importantes

Kafka armazena mensagens mesmo se elas já tenham sido consumidas por um de seus "consumers"

Algumas mensagens podem ser lidas múltiplas vezes por diferentes "consumers" em diferentes momentos

parâmetro no server.properties: log.retention.hours=168 # (7 dias)

#### Criando um novo consumidor

Em outro terminal: Terminal 3

➤ bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --topic cidades

Múltiplos consumidores e múltiplos produtores podem trocar mensagens via clusters kafka.

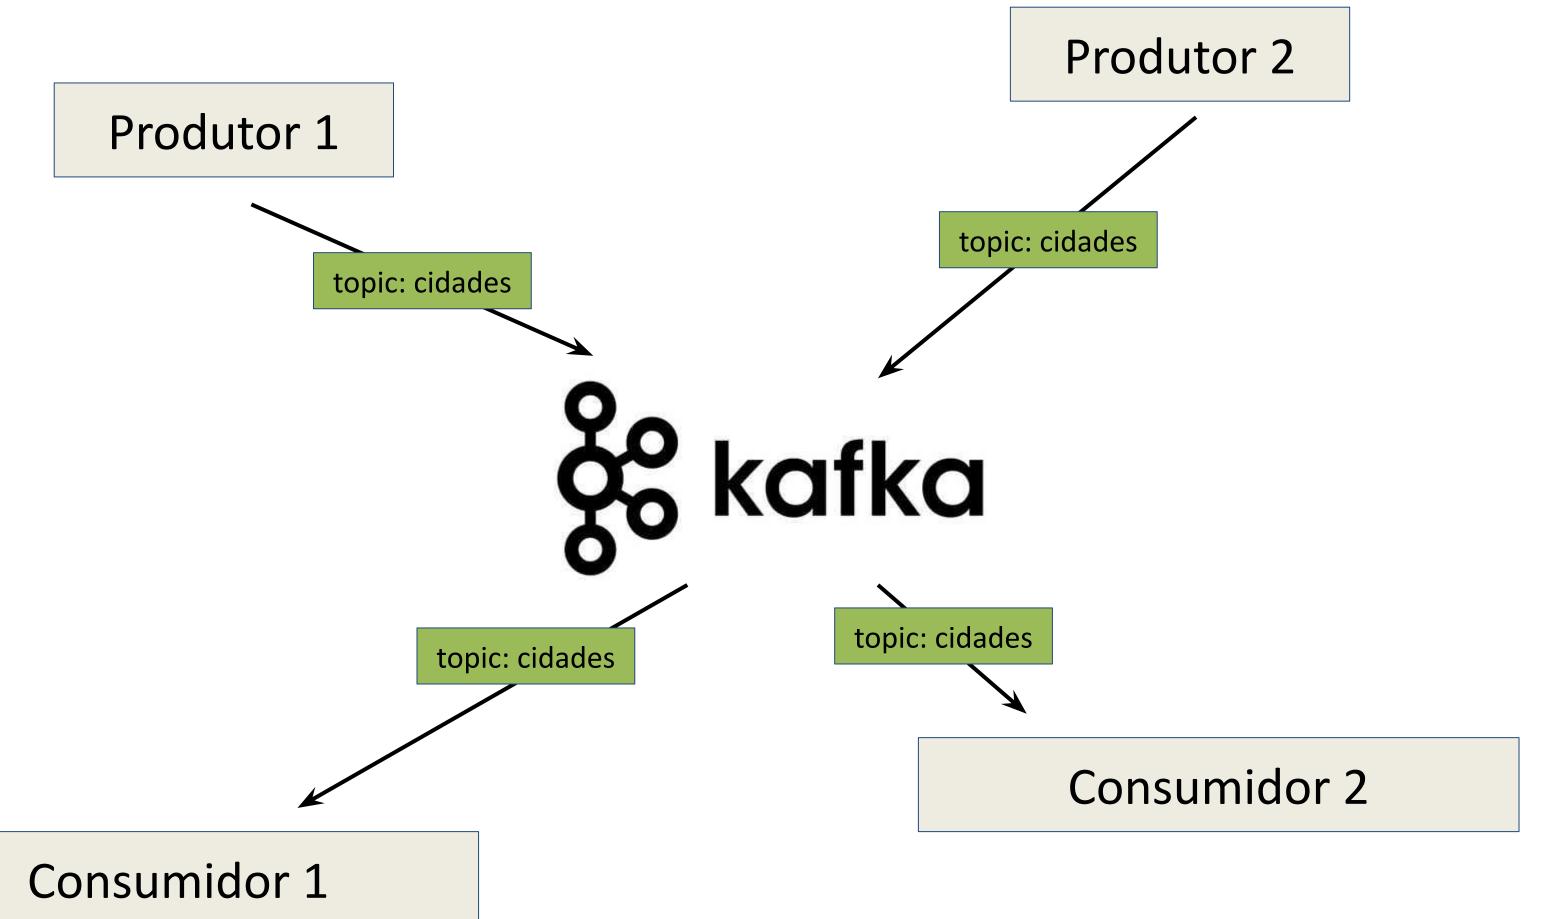
## Criando um novo produtor

Em outro terminal: Terminal 4

```
bin/kafka-console-producer.sh --broker-list
localhost:9092 --topic cidades
> Barcelona
```

Produtores não sabem nada sobre outros produtores.

## Esquema até então...



# Ao encerrar o produtor 2 (Terminal 4) o que acontece aos consumidores?

## Ao deletar o produtor 2

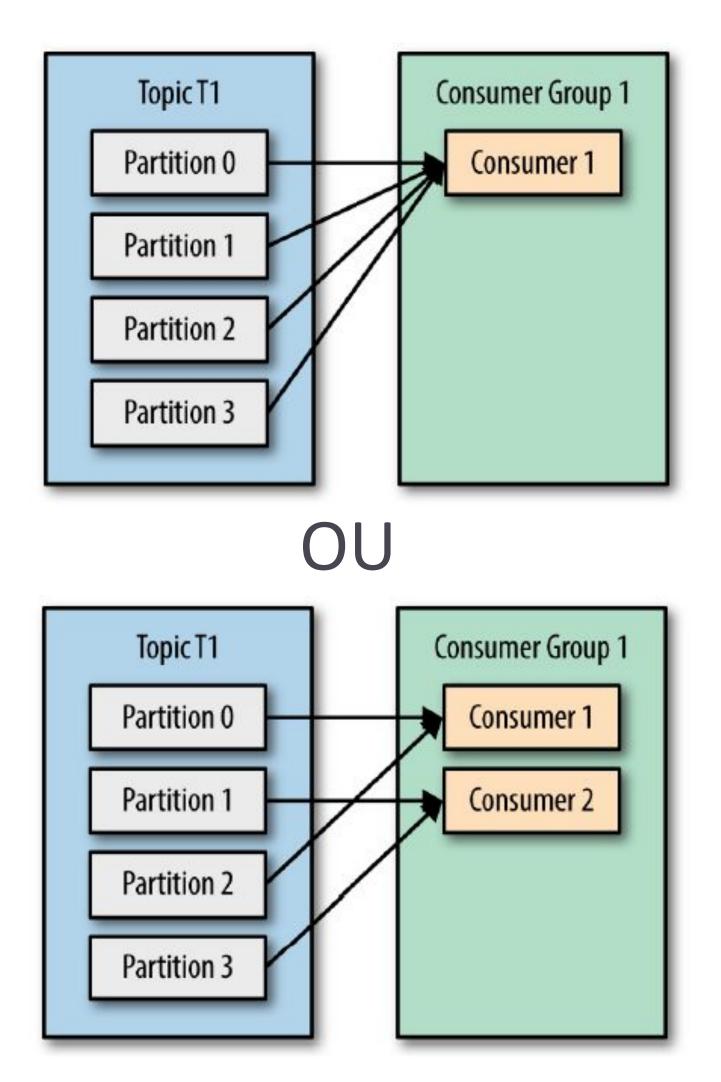
Resposta: Apenas deixam de receber mensagens do produtor excluído, mas continuam operando normalmente.

Consumidores recebem a mensagem do cluster kafka, independente dos produtores.

Agora, você deve deixar apenas um produtor e um consumidor

#### Offset e Partition

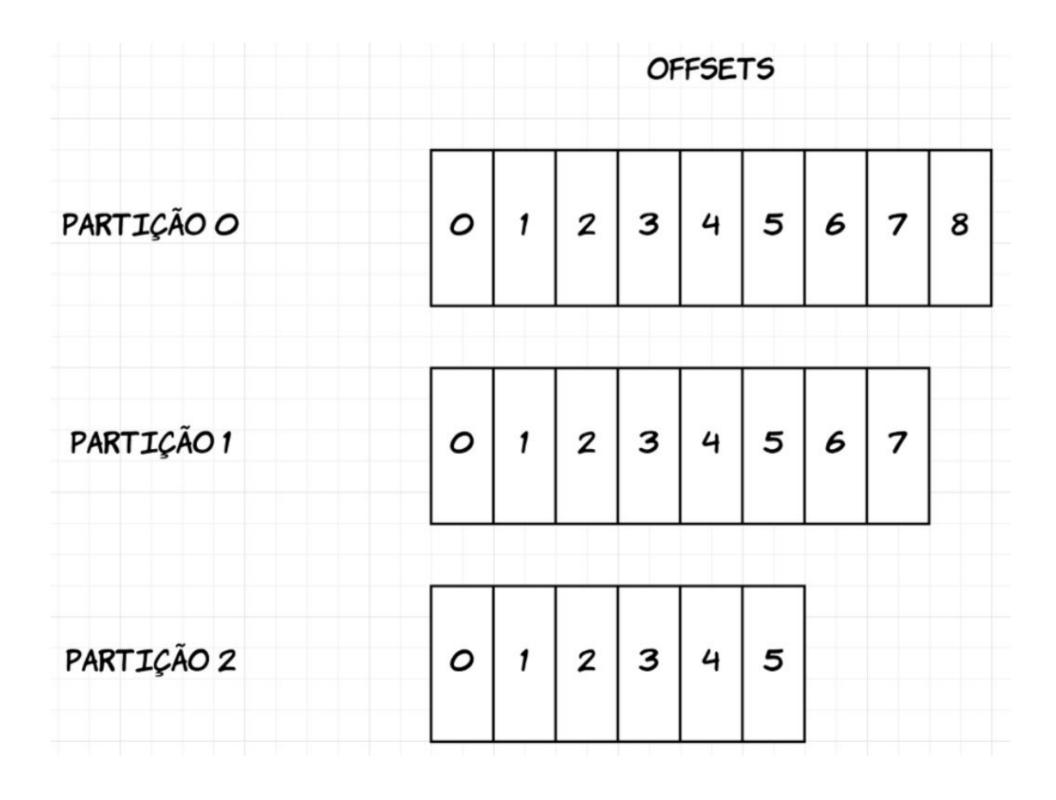
- Internamente, o Kafka quebra os tópicos em partições.
- O número de partições é indicado quando o tópico é criado.
- Não há limite de partições.
- Para facilitar a alta disponibilidade, as partições de um tópico são espalhadas entre os brokers do cluster.



• • •

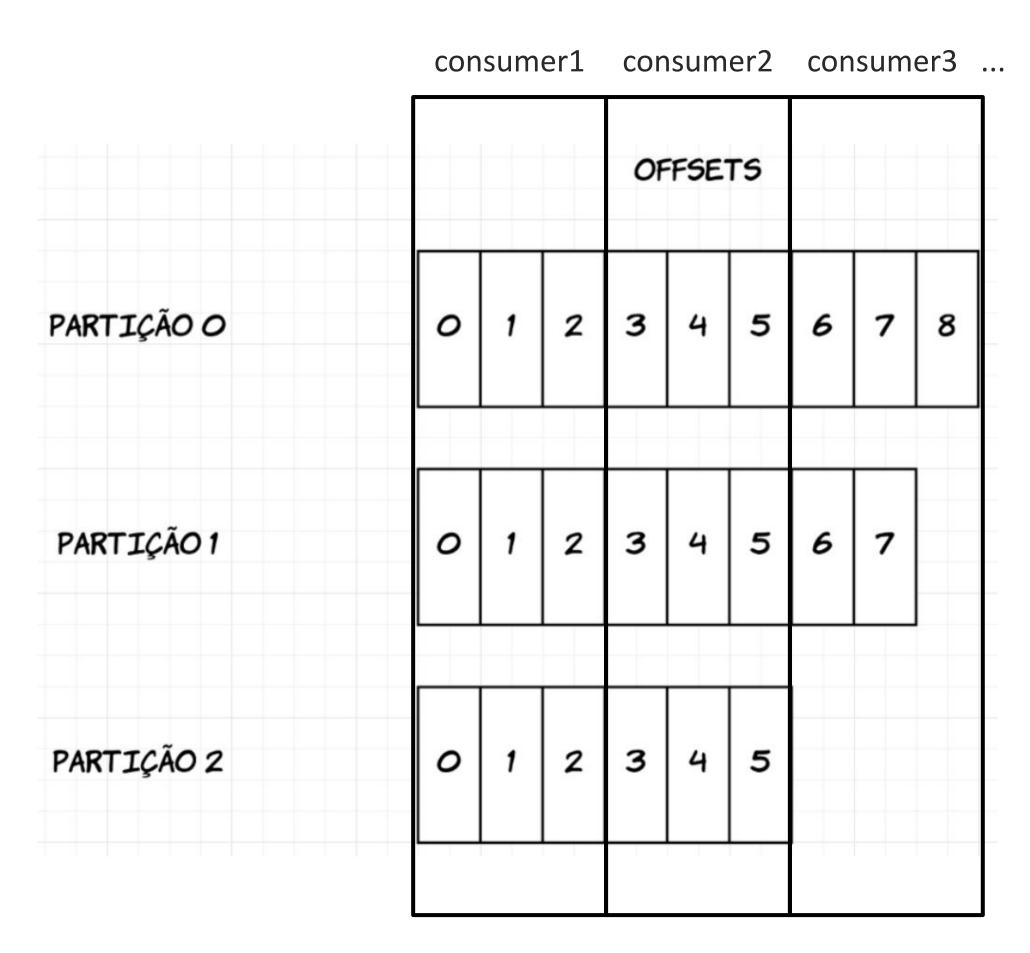
#### Offset e Partition

• Exemplo:



- O tópico possui 23 mensagens separadas em 3 partições.
- Dentro de cada partição, as mensagens são ordenadas por um metadado chamado offset.
- O offset serve para ordenar apenas no contexto da partição.
- Offsets iguais em partições diferentes resultam em mensagens diferentes.

#### Por que Partition?



- Proporciona paralelismo tanto para consumir quanto para produzir mensagens.
- Alguns consumidores trabalham com faixas de offset para não serem sobrecarregados.

#### Consumindo mensagens com offset

Terminal 2

#### Parar o terminal 2:

> ctrl+c

#### Executar novamente para obter mensagens com offset:

bin/kafka-console-consumer.sh --bootstrap-server
localhost:9092 --topic cidades --partition 0
--offset 4

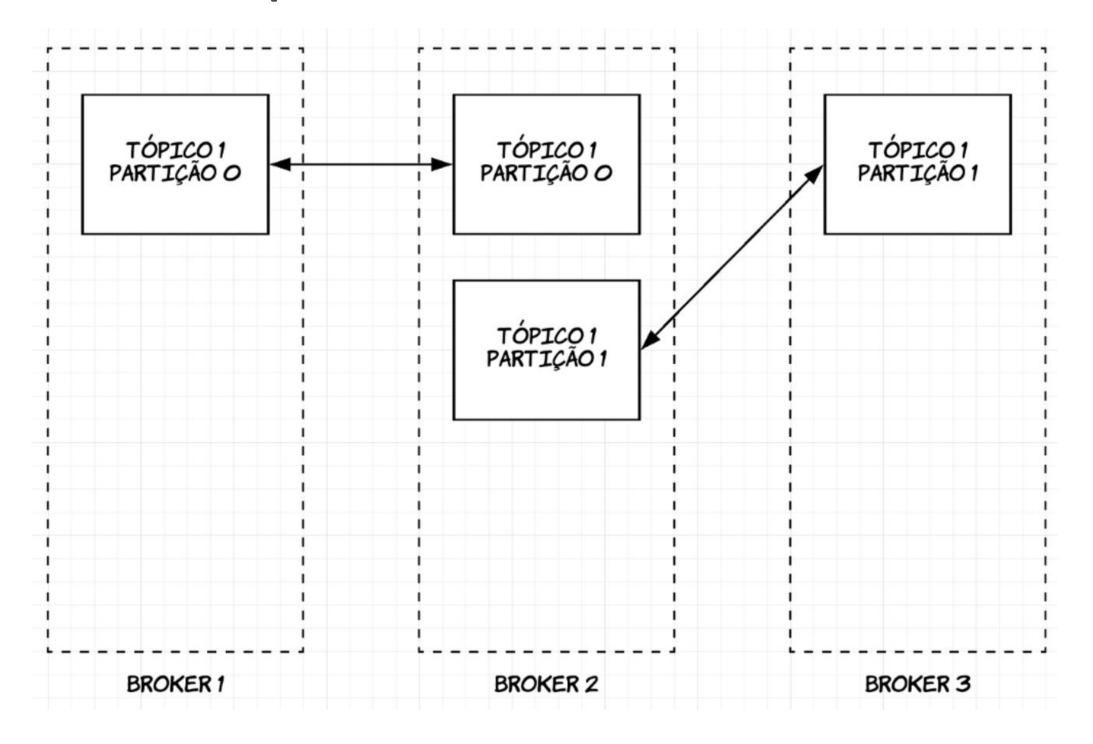
(Deixa de fora os 4 primeiros registros da partição 0)

## Fator de replicação

- O fator de replicação também é configurado quando o tópico é criado.
- O fator de replicação gera cópias das partições em outros brokers, assim se algum broker ficar indisponível, o Kafka continua sendo capaz de servir as mensagens sem interrupção no serviço.

## Fator de replicação

• Exemplo:



cluster com 3 brokers e 1 tópico, sendo o tópico com 2 partições e fator de replicação 2

- Caso o broker 2 fique indisponível o cluster não é afetado.
- Para descobrir o número de brokers que podem ser interrompidos sem afetar o cluster basta realizar o cálculo:
  - fator de replicação 1.
- Em nosso exemplo, o resultado seria (2 -1 = 1 broker).

## Criando um tópico com partições e rf

Em outro terminal: Terminal 3

➤ bin/kafka-topics.sh --bootstrap-server localhost:9092 --create --replication-factor 1 --partitions 3 --topic test

#### Criar um produtor test e inserir mensagens:

Terminal 1

>> bin/kafka-console-producer.sh --broker-list localhost:9092 --topic test

#### Criar um consumidor test: Terminal 2

➤ bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --topic test --partition 0 --from-beginning

Testar com offset

#### Comandos básicos do KAFKA - Resumo

Start Broker

bin/kafka-server-start.shconfig/server.properties

Start Zookeeper

bin/zookeeper-server-start.shconfig/zookeeper.properties

```
bin/kafka-topics.sh \
--bootstrap-server localhost:9092 \
--list
```

```
--bootstrap-server localhost:9092 \
--describe \
--topic test

Details about the topic
```

bin/kafka-topics.sh \

```
bin/kafka-console-producer.sh \
--broker-list localhost:9092 \
--topic test

Start console producer
```

```
bin/kafka-console-consumer.sh \
--bootstrap-server localhost:9092 \
--topic test \
--from-beginning Start console consumer
```

## KAFKA - Prática

#### Atividade 1

TO DO

- 1. Crie um tópico com o nome de vocês;
- 2. Liste os tópicos e verifique se o seu foi criado;
- 3. Gere dados para o tópico criado.

#### Obs.:

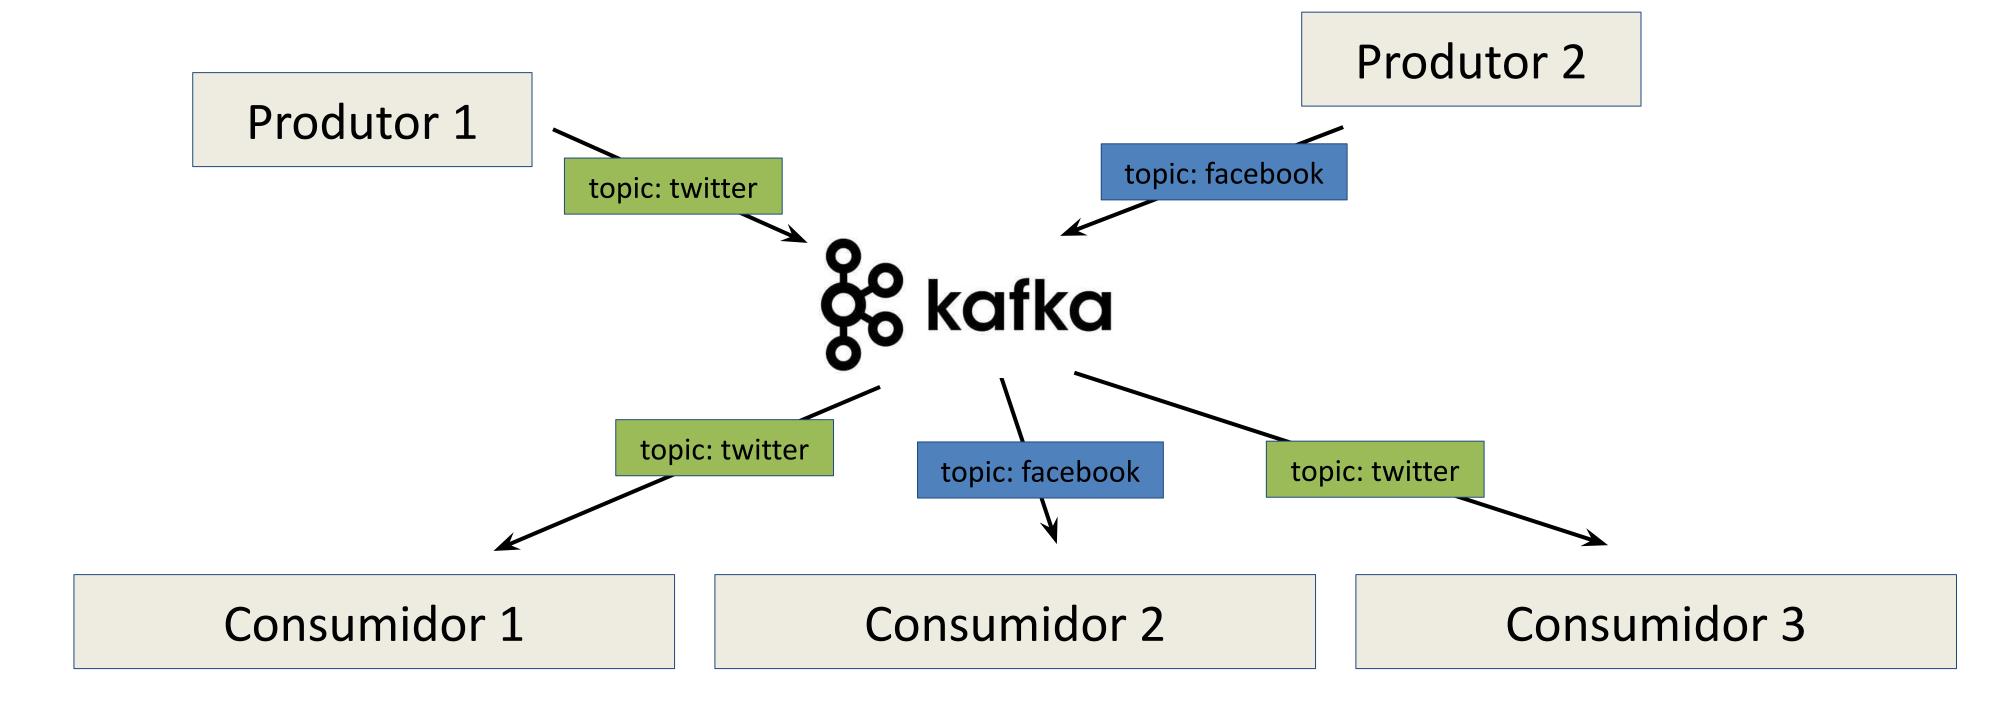
Endereço do zookeeper: localhost:2181

broker-list: localhost:9092

### Atividade 2

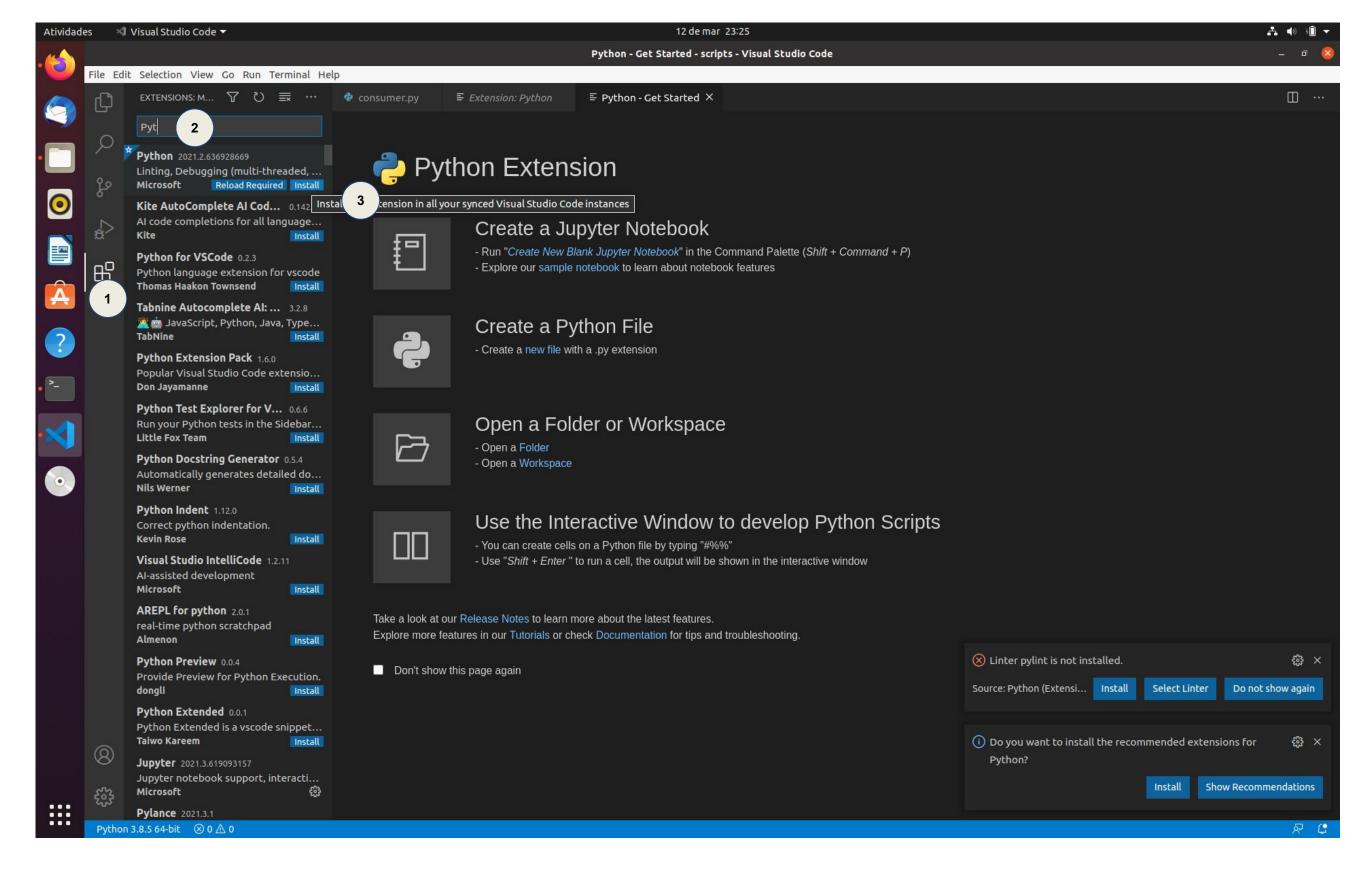
TO DO

Crie o seguinte esquema de troca de mensagens via streaming de dados no Apache KAKFA:



# KAFKA - Prática 2

Instalar dependência do Python no VSCode



Instalar a interface do Python com o KAKFA no Terminal

> pip3 install kafka-python

Criar uma pasta scripts no diretório ~ e abrir no VS Code

- > mkdir ~/scripts
- > code ~/scripts

### criar os seguintes scripts:

- > consumer.py
- > producer.py

Criar e executar os scripts juntamente com o Professor.

#### consumer.py

```
from kafka import KafkaConsumer
consumer = KafkaConsumer (
 'names',
 bootstrap servers=['localhost:9092']
for message in consumer:
 print (message)
```

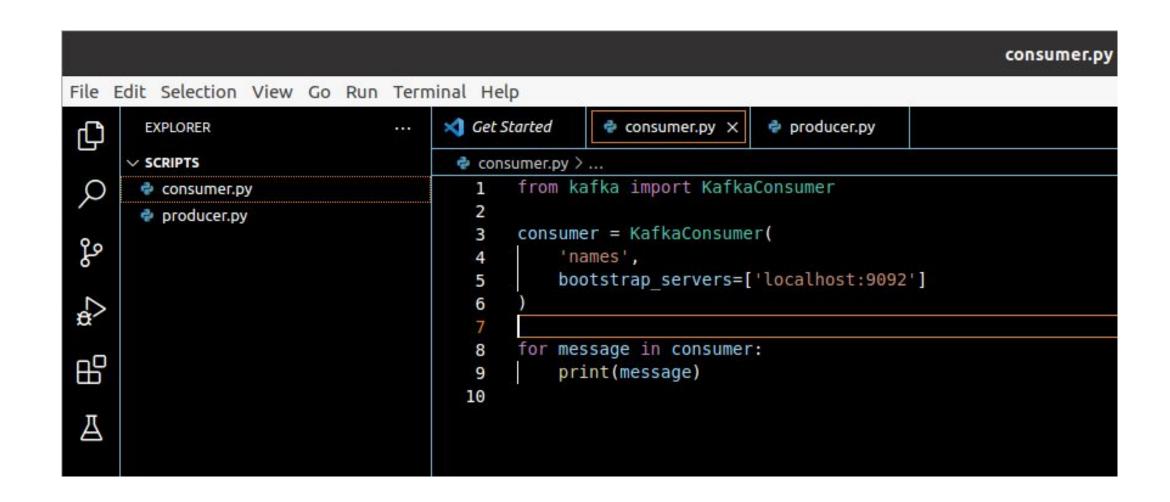
#### producer.py

```
import time
from kafka import KafkaProducer

producer = KafkaProducer(bootstrap_servers=['localhost:9092'])
producer.send('names', 'Felipe'.encode('utf-8'))

time.sleep(20)
```

Rodar o consumer.py e em seguida o producer.py



python3 consumer.py python3 producer.py

(em outro terminal)

# KAFKA - Prática 3

### Produtor/consumidor

#### Instalar dependência do fake names no python

➤ pip3 install Faker

### Baixar códigos python produtor/consumidor

```
> cd ~/scripts
```

```
>> wget
https://raw.githubusercontent.com/felipetimbo/streaming-data-course/
main/producer.py
```

wget
https://raw.githubusercontent.com/felipetimbo/streaming-data-course/
main/consumer.py

### Abrir scripts no VS Code

### Atividade 3

- Altere o script para serem enviados dados de 2 em 2 segundos;
- 2. Crie um segundo consumidor, e altere o produtor para enviar os dados para ambos os consumidores;
- Imprima nos consumidores apenas o nome das pessoas Fake que estão sendo produzidas, ao invés do conteúdo completo da mensagem;
- 4. Imprima no consumidor 1 o nome, e no consumidor 2 o sobrenome da pessoa Fake que é produzido.



# KAFKA - Prática 4

### Produtor/consumidor

### Baixar código único python produtor/consumidor

```
>> wget
https://raw.githubusercontent.com/felipetimbo/streaming-data-course/
main/producer_consumer.py
```

### Rodar script no VS Code

>> python3 producer\_consumer.py

### Atividade 4

- TO DO
- 1. Gere dados de quatro producers simultâneos
- 2. Aumente a frequência de geração das tuplas (geração mais rápida);
- 3. Filtre e imprima apenas por tuplas que possuem valores de peso maiores que 80;
- 4. Filtre e imprima apenas por tuplas que possuem valores de IMC acima de 35 ( $IMC = peso/altura^2$ ).

# Kafka Web Project

#### 1. Criar pasta do projeto

> mkdir ~/live-map

#### 2. Acessar via VSCode

> code ~/live-map

### 3. Ainda no terminal, instalar o Flask

> pip3 install flask

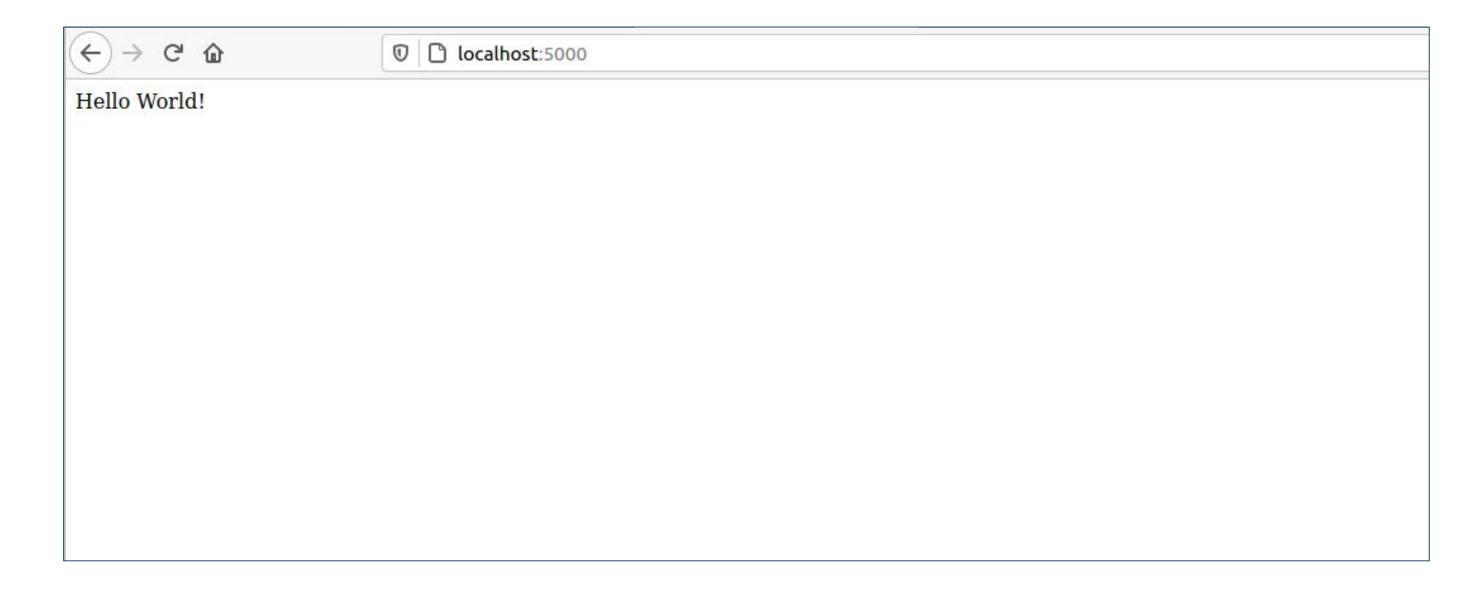
### 4. No VSCode, criar arquivo app.py e rodar:

```
from flask import Flask
app = Flask(__name__)  # cria uma instância do app

@app.route("/")  # no end point /
def hello():  # chama o método hello
    return "Hello World!"  # método retorna "hello world"

if __name__ == "__main__":  # rodando o python app.py
    app.run()  # roda o app flask
```

5. No navegador, Firefox por exemplo, acessar: http://localhost:5000/



- 6. No VSCode criar uma pasta chamada 'templates'
- 7. Criar arquivo index.html na pasta templates

#### index.html

```
<!DOCTYPE html>
<html>
 <head>
  <meta charset="utf-8">
  <!-- LEAFLET -->
  <link rel="stylesheet" href="https://unpkg.com/leaflet@1.7.1/dist/leaflet.css"</pre>
 integrity="sha512-xodZBNTC5n17Xt2atTPuE1HxjVMSvLVW9ocqUKLsCC5CXdbqCmblAshOMAS6/keqq/sMZMZ19scR4PsZChSR7A=="
 crossorigin=""/>
 <script src="https://unpkg.com/leaflet@1.7.1/dist/leaflet.js"</pre>
 integrity="sha512-XQoYMqMTK8LvdxXYG3nZ448hOEQiglfqkJs1NOQV44cWnUrBc8PkAOcXy20w0vlaXaVUearIOBhiXZ5V3ynxwA=="
 crossorigin=""></script>
  <!-- END LEAFLET -->
  <title>Live Map</title>
 </head>
 <body>
  <h1>Bus Live Map</h1>
  <!-- LEAFLET -->
  <div id="mapid" style = "width:900px; height:580px;"></div>
  <script src="../static/livemap.js"></script>
  <!-- END LEAFLET -->
 </body>
</html>
```

#### 8. Cadastrar um token no mapbox

https://account.mapbox.com/



Dashboard

Tokens

Statistics

Invoices

Settings



#### Access tokens

+ Create a token

You need an API access token to configure Mapbox GL JS, Mobile, and Mapbox web services like routing and geocoding. Read more about API access tokens in our documentation.

- 9. No VSCode criar uma pasta chamada 'static' na raiz do projeto
- 10. Criar arquivo livemap.js

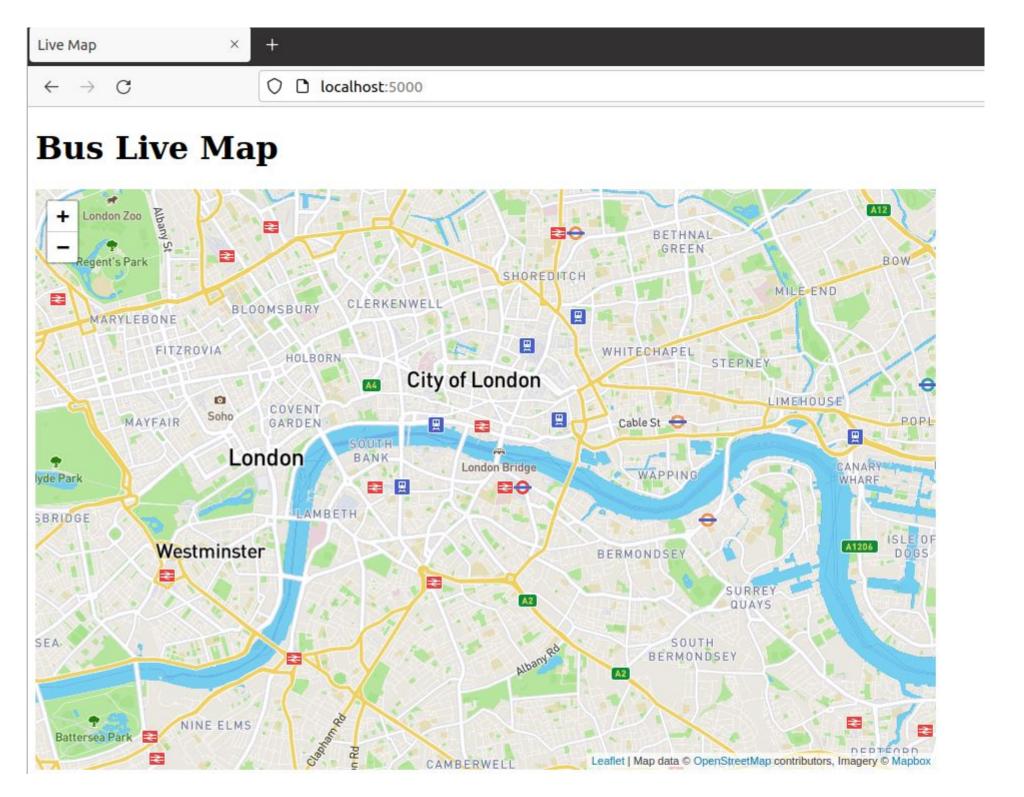
#### livemap.js

```
var mymap = L.map('mapid').setView([51.505, -0.09], 13);
L.tileLayer('https://api.mapbox.com/styles/v1/{id}/tiles/{z}/{x}/{y}?access_token={accessToken}', {
  attribution: 'Map data © <a
href="https://www.openstreetmap.org/copyright">OpenStreetMap</a> contributors, Imagery © <a
href="https://www.mapbox.com/">Mapbox</a>',
  maxZoom: 18,
  id: 'mapbox/streets-v11',
  tileSize: 512,
  zoomOffset: -1,
  accessToken:
'pk.eyJ1ljoiZmVsaXBldGltYm8iLCJhljoiY2ttNnM0ZGgyMDlzZTJxcXk1bzdyeWxvZCJ9.WdumAW
A63xkYg-K6hrfXFA'
}).addTo(mymap);
```

#### 11. Alterar o app.py

```
from flask import Flask, render_template
...
@app.route("/")
def index():
    return(render_template('index.html'))
```

- 12. Derrubar a aplicação e subir novamente
- 13. No navegador, acessar http://localhost:5000/ e visualizar o mapa.



- 14. No VSCode, Criar uma pasta chamada 'data' na raiz do projeto
- 15. Via terminal, fazer o download dos dados json para a pasta 'data'
  - > cd ~/live-map/data/
  - wget
    https://raw.githubusercontent.com/felipetimbo/streamingdata-course/main/bus1.json

16. Criar um arquivo chamado producer1.py na raiz do projeto

#### producer1.py

```
from kafka import KafkaProducer import json from datetime import datetime import uuid import time

#LER AS COORDENADAS GEOJSON
```

```
input_file = open('./data/bus1.json')
json_array = json.load(input_file)
coordinates = json_array['features'][0]['geometry']['coordinates']
```

```
#GERAR ID UNICO def generate_uuid(): return uuid.uuid4()
```

```
#KAFKA PRODUCER producer = KafkaProducer(bootstrap_servers='localhost:9092')
```

#### producer1.py

```
#CONSTRUIR A MENSAGEM E ENVIAR VIA KAFKA
data = {}
data['busline'] = '00001'
def generate_checkpoint(coordinates):
  i = 0
  while i < len(coordinates):
     data['key'] = data['busline'] + '_' + str(generate_uuid())
     data['timestamp'] = str(datetime.utcnow())
     data['latitude'] = coordinates[i][1]
     data['longitude'] = coordinates[i][0]
     message = json.dumps(data)
     print(message)
     producer.send('busao', message.encode('ascii'))
     # producer.produce(message.encode('ascii'))
     time.sleep(1)
     #if bus reaches last coordinate, start from beginning
     if i == len(coordinates)-1:
       i = 0
     else:
       i += 1
generate_checkpoint(coordinates)
```

- 17. Executar o arquivo producer1.py
  - > python3 producer1.py

- 18. Em um outro terminal, verificar se os dados estão chegando via consumidor
  - ➤ bin/kafka-console-consumer.sh --bootstrap-server localhost:9092 --topic busao

### 19. Criar o consumidor no arquivo 'app.py'

```
from flask import Flask, render template, Response, stream with context
from kafka import KafkaConsumer
@app.route('/topic/<topicname>')
def streamed response (topicname):
    stream = KafkaConsumer(topicname, bootstrap servers='localhost:9092')
    def generate():
        for i in stream:
            yield "{}".format(i.value.decode())
    return Response (stream with context (generate ()))
```

### 20. Criar um produtor para o consumidor anterior

bin/kafka-console-producer.sh --broker-list
localhost:9092 --topic busao2

#### 21. Rodar a aplicação:

- > python3 app.py
- 22. Acessar o browser em: http://localhost:5000/topic/busao2
- 23. Emitir uma mensagem no produtor criado e visualizar ela no browser

- 24. Derrubar a aplicação (ctrl+c)
- 25. Adicionar ao livemap.js o código a seguir
- 26. Verificar o arquivo final app.py

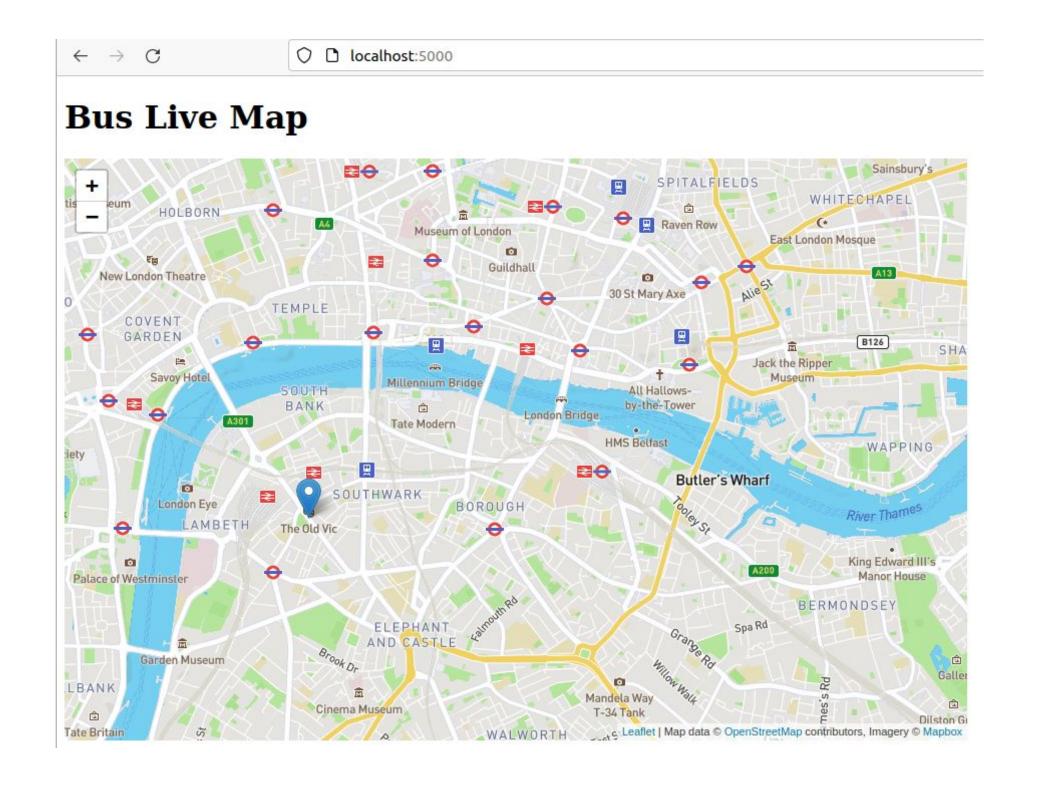
#### livemap.js

```
var mapMarkers1 = []
var source = new EventSource('/topic/busao'); // NOME DO TOPICO
source.addEventListener('message', function(e){
 console.log('Message');
 obj = JSON.parse(e.data);
 console.log(obj);
 if(obj.busline == '00001') {
  for (var i = 0; i < mapMarkers1.length; i++) {
   mymap.removeLayer(mapMarkers1[i]);
  marker1 = L.marker([obj.latitude, obj.longitude]).addTo(mymap);
  mapMarkers1.push(marker1);
}, false);
```

```
app.py
```

```
from flask import Flask, render_template, Response, stream with context
from kafka import KafkaConsumer
app = Flask( name )
@app.route('/')
def index():
  return(render_template('index.html'))
@app.route('/topic/<topicname>')
def streamed response(topicname):
  stream = KafkaConsumer(topicname, bootstrap_servers='localhost:9092')
  def generate():
    for i in stream:
       yield 'data:{0}\n\n'.format(i.value.decode())
  return Response(stream with context(generate()), mimetype="text/event-stream")
if name == " main ":
  app.run()
```

### 27. Rodar a aplicação



#### Para adicionar mais ônibus

#### 28. Baixar os dados de mais dois ônibus no terminal:

- > cd ~/live-map/data/
- wget
  https://raw.githubusercontent.com/felipetimbo/streamingdata-course/main/bus2.json
- wget
  https://raw.githubusercontent.com/felipetimbo/streamingdata-course/main/bus3.json

#### Para adicionar mais ônibus

29. Criar producer2.py e producer3.py e modificar os ID's:

```
data['busline'] = '00002' # no producer2.py
data['busline'] = '00003' # no producer3.py
```

30. Alterar livemap.js

#### livemap.js

```
mapMarkers1 = [];
mapMarkers2 = [];
mapMarkers3 = [];
var source = new EventSource('/topic/busao');
source.addEventListener('message', function(e){
 console.log('Message');
 obj = JSON.parse(e.data);
 console.log(obj);
 if(obj.busline == '00001') {
  for (var i = 0; i < mapMarkers1.length; i++) {
   mymap.removeLayer(mapMarkers1[i]);
  marker1 = L.marker([obj.latitude, obj.longitude]).addTo(mymap);
  mapMarkers1.push(marker1);
 if(obj.busline == '00002') {
  for (var i = 0; i < mapMarkers2.length; i++) {
   mymap.removeLayer(mapMarkers2[i]);
  marker2 = L.marker([obj.latitude, obj.longitude], {color:'red'}).addTo(mymap);
  mapMarkers2.push(marker2);
 if(obj.busline == '00003') {
  for (var i = 0; i < mapMarkers3.length; i++) {
   mymap.removeLayer(mapMarkers3[i]);
  marker3 = L.marker([obj.latitude, obj.longitude]).addTo(mymap);
  mapMarkers3.push(marker3);
}, false);
```

# Dúvidas?