# Streaming de Dados em Tempo Real: Aula 3

Prof. Felipe Timbó



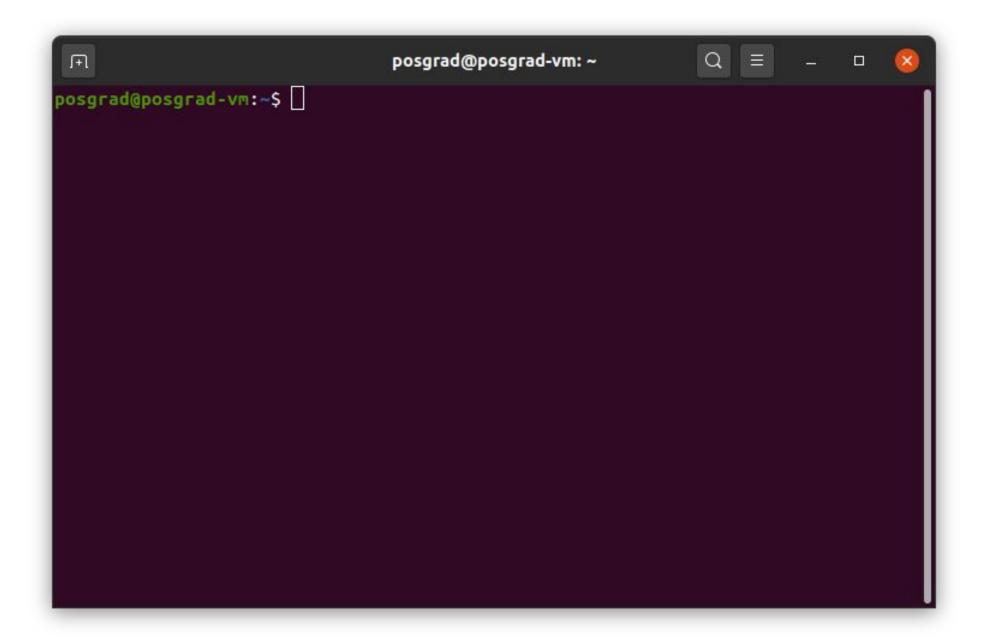
# Ementa (dia 3)

- Introdução ao Apache Spark
  - Ações e Transformações
  - RDD's e Dataframes
- Manipulação de dados com Apache Spark e Python

# Instalando o Spark

### Iniciando a VM

- 1. Iniciar a VM com Ubuntu configurada nas aulas passadas
- 2. Logar na VM e abrir um Terminal



### Instalando o Spark no Ubuntu

3. Baixar Spark + Hadoop com o comando abaixo:

```
wget
https://dlcdn.apache.org/spark/spark-3.2.3/spa
rk-3.2.3-bin-hadoop2.7.tgz
```

### Instalando o Spark no Ubuntu

#### 4. Extrair os arquivos:

```
➤ tar -xvzf spark-*
```

#### 5. Mover os arquivos para o diretório opt/spark:

```
> sudo mv spark-3.2.3-bin-hadoop2.7 /opt/spark
```

# Configurando o ambiente Spark

#### 6. Configurar as variáveis de ambiente com os comandos:

```
> echo "export SPARK_HOME=/opt/spark" >> ~/.profile
> echo "export PATH=$PATH:/opt/spark/bin:/opt/spark/sbin" >> ~/.profile
> echo "export PYSPARK PYTHON=/usr/bin/python3" >> ~/.profile
```

#### 7. Garantir que as novas variáveis podem ser acessadas:

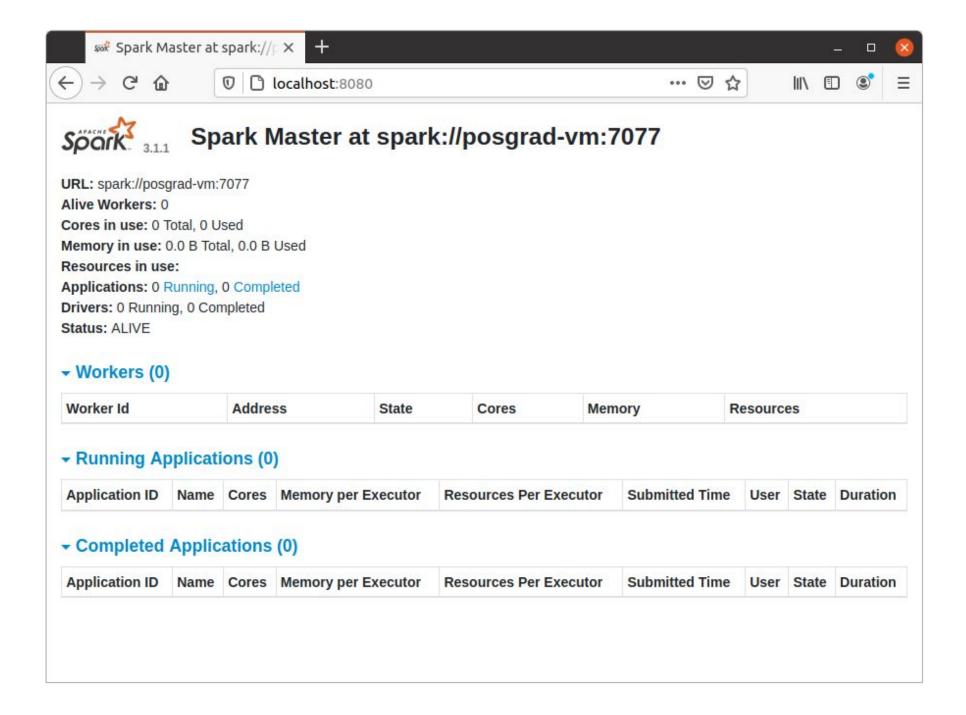
> source ~/.profile

### Iniciando o Spark

8. Iniciar o spark:



9. Acessar localhost:8080 no navegador e visualizar o Spark rodando:

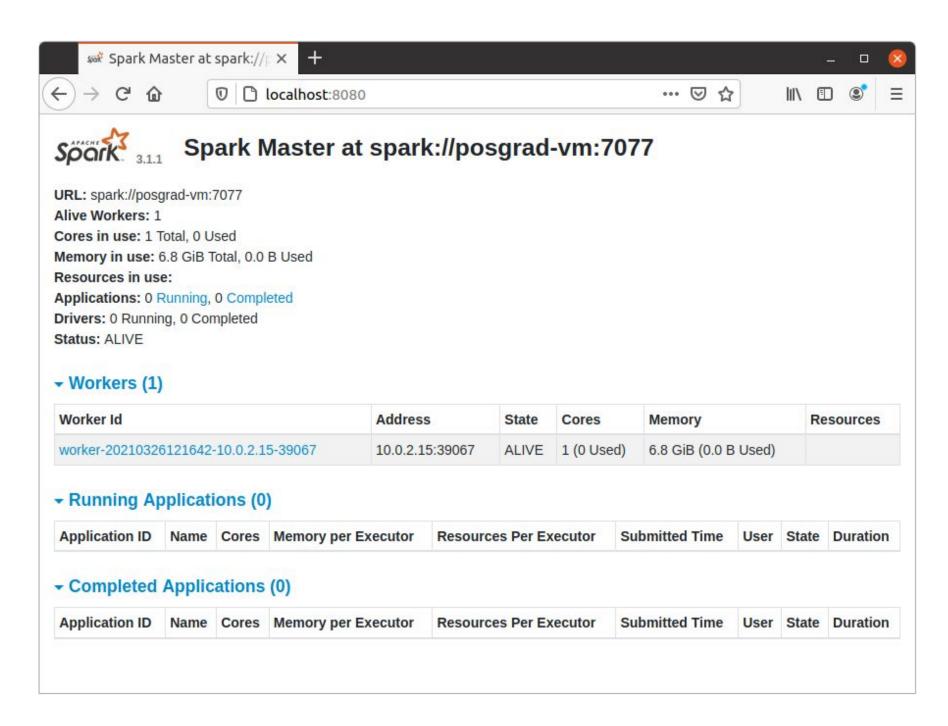


### Iniciando o Spark

10. Iniciar o nó trabalhador:

>> start-worker.sh spark://posgrad-VirtualBox:7077

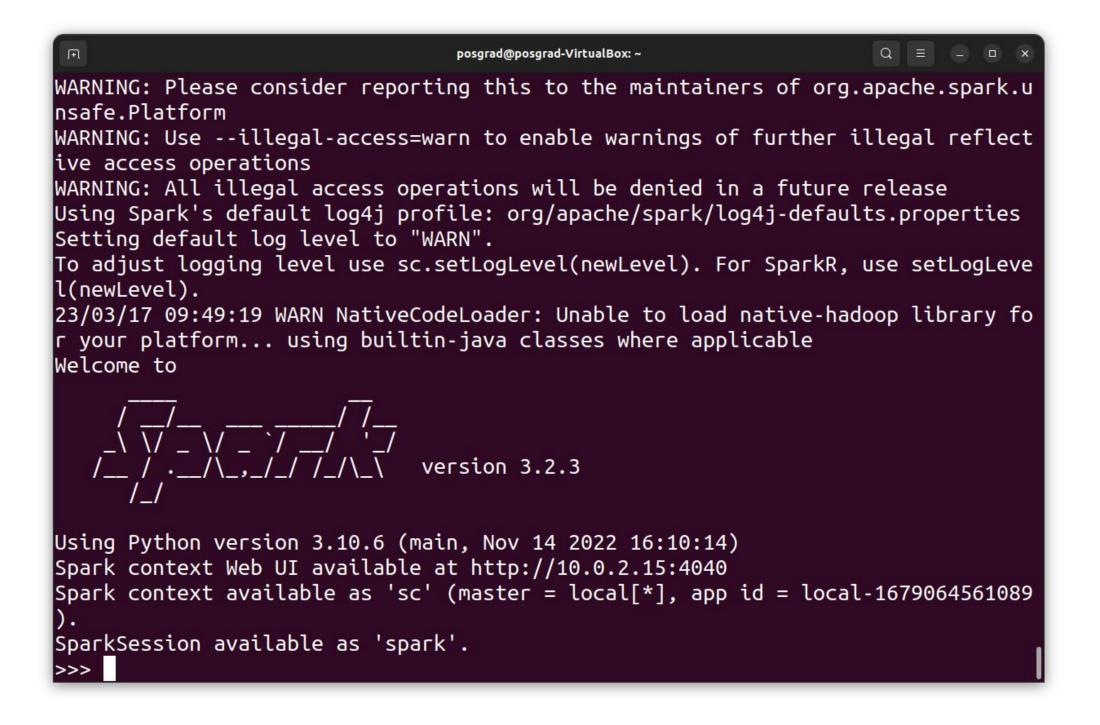
11. Acessar localhost:8080 no navegador e visualizar o Worker ativo:



# Rodando o Spark Shell

#### 12. Verificar a instalação do Spark Shell com seguinte comando:

> pyspark



Caso apareça a imagem ao lado, você instalou o Spark com sucesso:)

## Primeiros passos com o Spark

Finalmente, após rodar o Spark, você poderá testar os seguintes comandos no próprio Spark Shell:

- $\triangleright$  nums = sc.parallelize([1, 2, 3, 4])
- > nums.count()
- > nums.collect()

#### Para sair, basta digitar o comando:

```
> exit()
```

```
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLeve
l(newLevel).
23/03/17 09:49:19 WARN NativeCodeLoader: Unable to load native-hadoop library fo
 your platform... using builtin-java classes where applicable
Welcome to
Using Python version 3.10.6 (main, Nov 14 2022 16:10:14)
Spark context Web UI available at http://10.0.2.15:4040
Spark context available as 'sc' (master = local[*], app id = local-1679064561089
SparkSession available as 'spark'.
>>> nums = sc.parallelize([1, 2, 3, 4])
>>> nums.count()
>>> nums.collect()
[1, 2, 3, 4]
>>> exit()
 osgrad@posgrad-VirtualBox:~S
```

# Spark

# Spark

- "A fast and general engine for large-scale data processing"
- Manipulações, transformações e análises complexas
  - Aprendizagem de máquina
  - Mineração de dados
  - Análise de grafos
  - Streaming
- Linguagens: Python, Java, e Scala

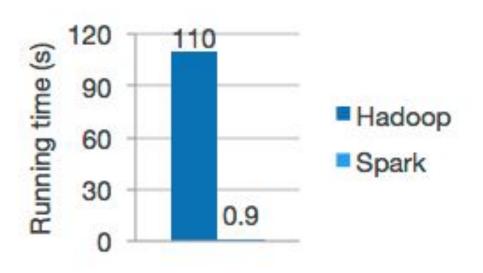
## Spark - Quem usa?

- Amazon
- Ebay: análise de log e agregação
- NASA JPL: Deep Space Network
- Groupon
- TripAdvisor
- Etc. https://spark.apache.org/powered-by.html



### Spark - Desempenho

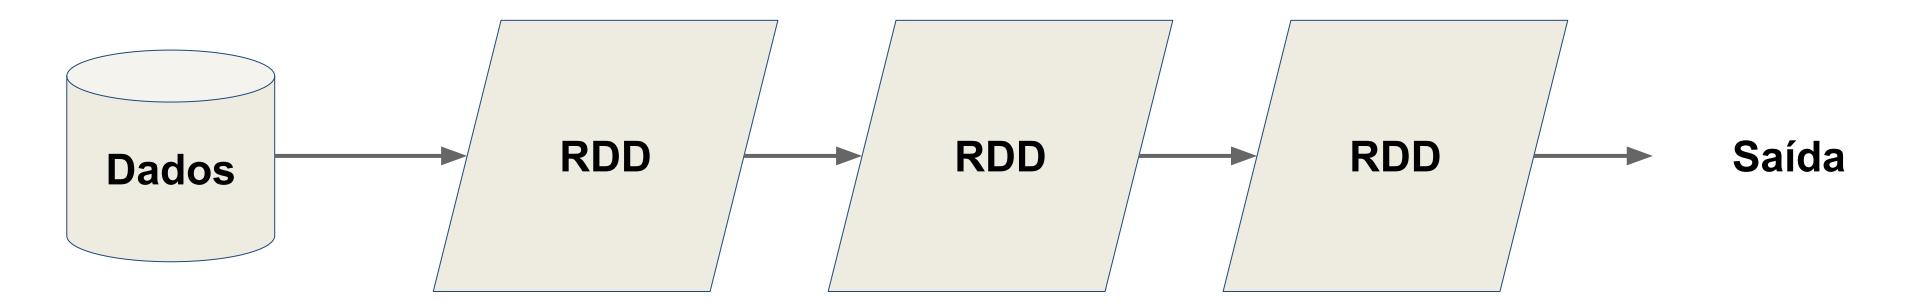
- 100x mais rápido que o Hadoop MapReduce em memória
- 10x mais rápido que o Hadoop MapReduce em disco
- 2x a 5x menos código



Logistic regression in Hadoop and Spark

### RDD - Resilient Distributed Dataset

- Abstração fornecida pelo Spark para a manipulação de dados.
- Representação de um dado distribuído pelos nós do cluster que pode ser operado em paralelo.
- Transformações e Ações



### RDD - Resilient Distributed Dataset

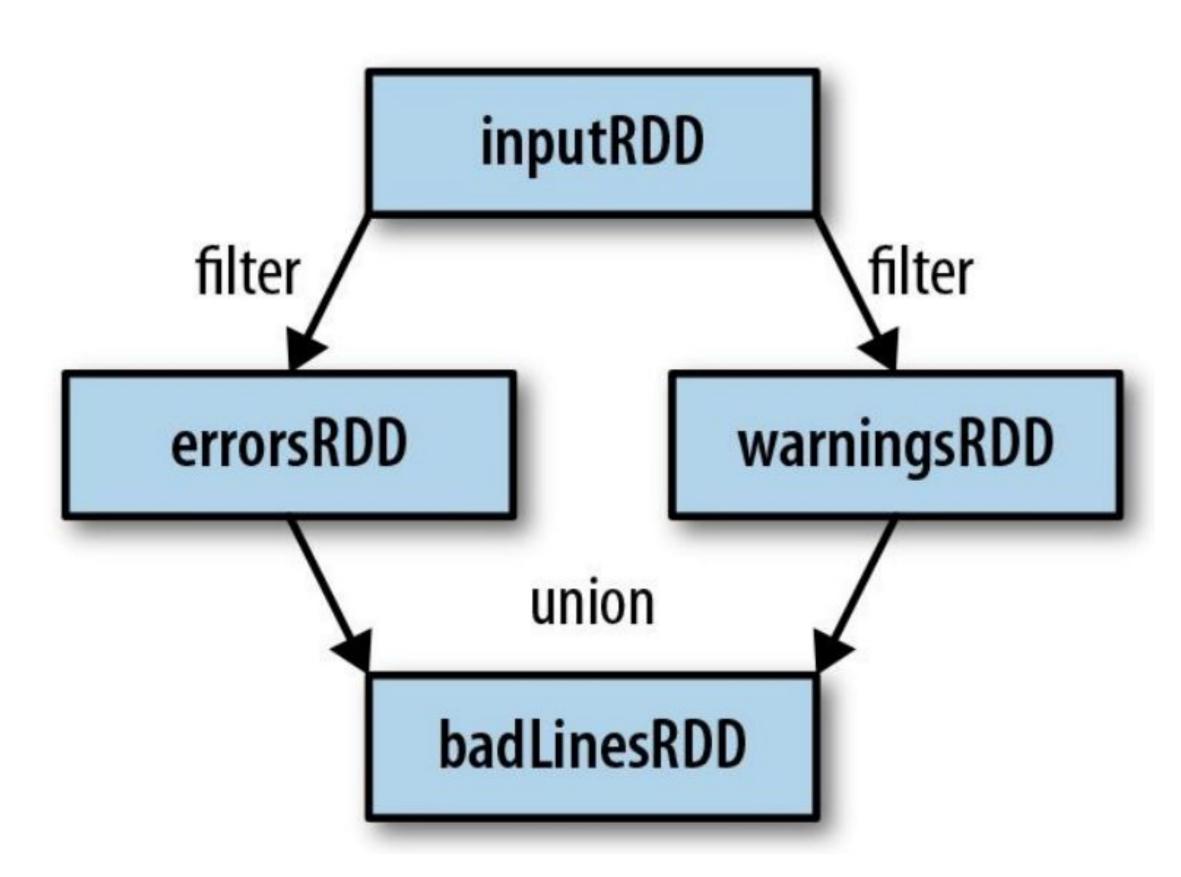
Particionado

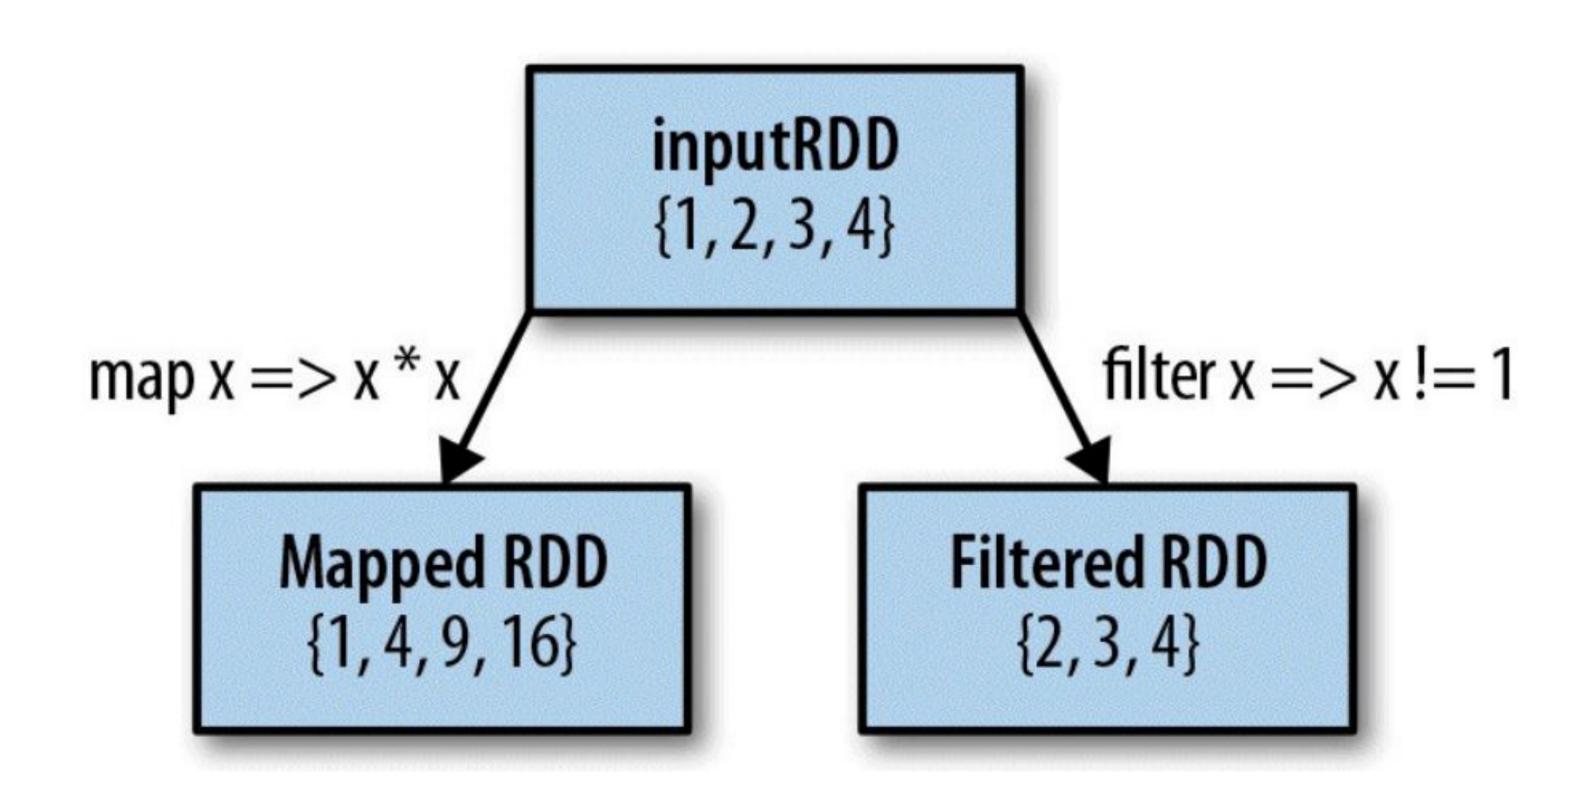
Dividido em nós de um cluster Imutável

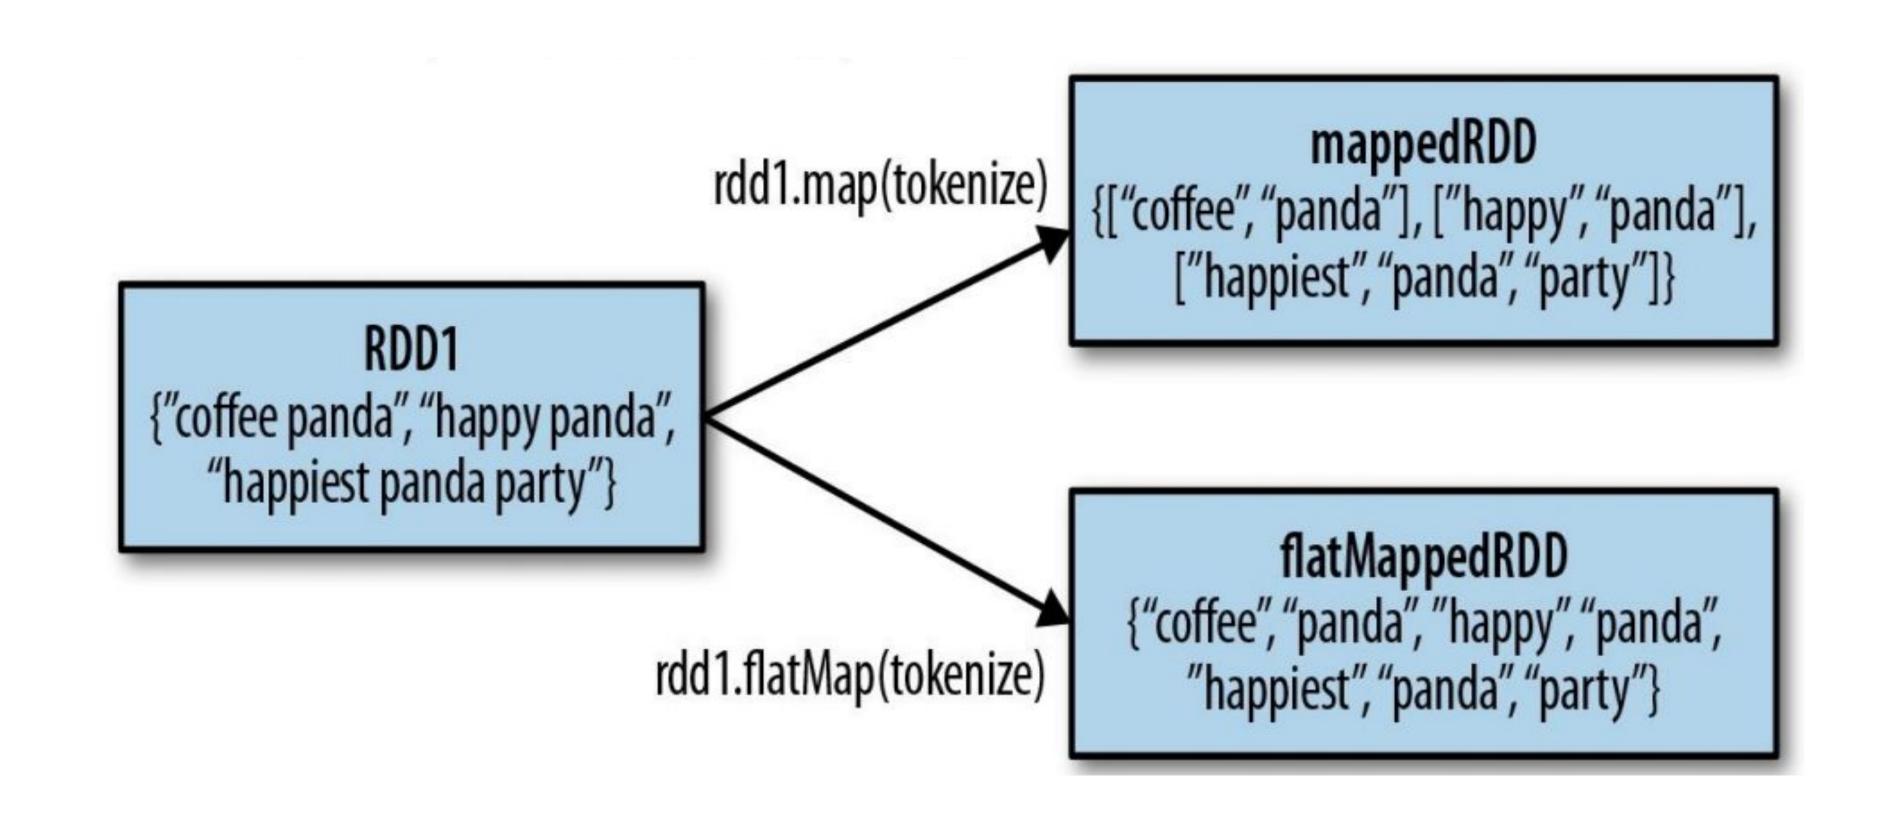
RDDs, uma vez criados, não podem ser alterados Resiliente

Podem ser reconstruídos mesmo se um nó caia

- map
- flatmap
- filter
- distinct
- sample
- union, intersection, subtract, cartesian
- etc.







RDD1 {coffee, coffee, panda, monkey, tea}

RDD2 {coffee, money, kitty}

RDD1.distinct()
{coffee, panda,
monkey, tea}

RDD1.union(RDD2)
{coffee, coffee, coffee, panda, monkey, monkey, tea, kitty}

RDD1.intersection(RDD2) {coffee, monkey}

RDD1.subtract(RDD2) {panda, tea}

Transformação	Descrição	Exemplo	Resultado
map(func)	retorna um RDD depois de processar cada elemento com a função <i>func</i>	sc.parallelize([1, 2, 3, 4,5]).map(lambda x: x + 10).collect()	{ 11, 12, 13, 14, 15 }
filter(func)	Retorna um RDD depois de selecionar os enementos onde <i>func</i> é verdadeira	sc.parallelize([1, 2, 3, 4, 5]).filter(lambda x: x == 3).collect()	3
flatMap(func)	Similar ao map, mas cada item pode ser mapeado para 0 ou mais items (func deve retornar uma sequência, ao invés de um item).	sc.parallelize(["this is line 1", "this is the second line"]).flatMap(lambda line: line.split(" ")).collect()	['this', 'is', 'line', '1', 'this', 'is', 'the', 'second', 'line']

Transformação	Descrição	Exemplo	Resultado
union(otherDataset)	Retorna uma coleção que contém a união de todos os elementos da fonte e do argumento.	sc.parallelize([1, 2, 3, 4, 5]).union(sc.parallelize([6, 7, 8, 9, 10])).collect()	{1,2,3,4,5,6,7,8,9,10}
intersection(otherDa taset)	Retorna um RDD que contém uma interseção dos elementos da fonte e do argumento.	sc.parallelize([1, 2, 3, 4, 5]).intersection(sc.parallelize([4, 5, 6, 7, 8])).collect()	{5,4}
distinct([numTasks]))	Retorna uma coleção que contém os elementos distintos da fonte.	sc.parallelize([(1,2), (1,2), (1,2), (3,4), (5,6), (7,8), (7,8)]).distinct().collect()	{(1,2), (5,6), (7,8), (3,4)}
reduceByKey(func, [numTasks])	Quando invocado sobre uma coleção de pares (k, v), retorna uma coleção de pares (k, v) onde os valores de cada chave são agregados usando pela função <i>func</i> , que deve ser do tipo (v, v).	sc.parallelize([(1,2), (1,2), (1,2), (3,4), (5,6), (7,8), (7,8)]).reduceByKey(lambda x, y: x + y).collect()	(1,6) (3,4) (7,16) (5,6)

Transformação	Descrição	Exemplo		Resultado
sortByKey([ascendin g], [numTasks])	Quando invocado sobre uma coleção de pares (k, v), onde k implementa Ordered, retorna uma coleção de pares (k, v) ordenados pela chaves.	sc.parallelize([(1,2), (1,2), (1,2), (3,4), (5,6), (7,8), (7,8)]).sortByKey().collect()	,	(1,2)
				(1,2)
				(1,2)
				(3,4)
				(5,6)
				(7,8)
				(7,8)
<b>join</b> (otherDataset, [numTasks])	Quando invocado sobre uma coleção de	sc.parallelize([(1,"um"), (2,"dois"),		(1,(um,one))
	pares do tipo (k, v) e (k, w), retorna uma	(3,"tres")]).join(sc.parallelize([(1,"one"), (2, "two"), (3,		(3,(tres,three))
	coleção de pares (k, (v, w)).	"three")])).collect()		(2,(dois,two))

# Ações

- collect
- count
- countByValue
- take
- top
- reduce
- etc.

Obs. Lazy evaluation: nada acontece até uma dessas funções serem chamadas!

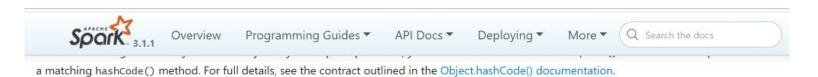
# Ações

Ações	Descrição	Exemplo	Resultado
reduce(func)	Agrega os elementos de uma coleção usando a função func (que precisa de dois argumentos, retornando um). A função deve ser acumulativa ou associativa, para ser computada corretamente em paralelo.	sc.parallelize([1,2,3,4,5]).reduce(lambda x, y: x + y )	15
collect()	Retorna todos os elementos de uma coleção como um vetor dentro do programa driver.	sc.parallelize([1,2,3,4,5]).collect()	Array(1, 2, 3, 4, 5)
count()	Retorna o número de elementos dentro da coleção de dados.	sc.parallelize([1,2,3,4,5]).count()	5
first()	Retorna o primeiro elemento da coleção de dados.	sc.parallelize([1,2,3,4,5]).first()	1
take(n)	Return an array with the first <i>n</i> elements of the dataset.	sc.parallelize([1,2,3,4,5]).take(2)	Array(1, 2)

# Mais Ações e Transformações em...

and pair RDD functions doc (Scala, Java) for details.

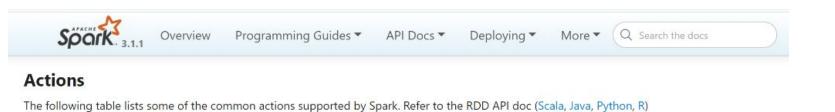
#### https://spark.apache.org/docs/latest/rdd-programming-guide.html



#### Transformations

The following table lists some of the common transformations supported by Spark. Refer to the RDD API doc (Scala, Java, Python, R) and pair RDD functions doc (Scala, Java) for details.

Transformation	Meaning
map(func)	Return a new distributed dataset formed by passing each element of the source through a function <i>func</i> .
filter(func)	Return a new dataset formed by selecting those elements of the source on which func returns true.
flatMap(func)	Similar to map, but each input item can be mapped to 0 or more output items (so <i>func</i> should return a Seq rather than a single item).
mapPartitions(func)	Similar to map, but runs separately on each partition (block) of the RDD, so <i>func</i> must be of type Iterator <t> =&gt; Iterator<u> when running on an RDD of type T.</u></t>
mapPartitionsWithIndex(func)	Similar to mapPartitions, but also provides <i>func</i> with an integer value representing the index of the partition, so <i>func</i> must be of type (Int, Iterator <t>) =&gt; Iterator<u> when running on an RDD of type T.</u></t>
sample(withReplacement, fraction, seed)	Sample a fraction <i>fraction</i> of the data, with or without replacement, using a given random number generator seed.
union(otherDataset)	Return a new dataset that contains the union of the elements in the source dataset and the argument.
intersection(otherDataset)	Return a new RDD that contains the intersection of elements in the source dataset and the argument.
distinct([numPartitions]))	Return a new dataset that contains the distinct elements of the source dataset.
groupByKey([numPartitions])	When called on a dataset of (K, V) pairs, returns a dataset of (K, Iterable < V > ) pairs.  Note: If you are grouping in order to perform an aggregation (such as a sum or



Action	Meaning
reduce(func)	Aggregate the elements of the dataset using a function <i>func</i> (which takes two arguments and returns one). The function should be commutative and associative so that it can be computed correctly in parallel.
collect()	Return all the elements of the dataset as an array at the driver program. This is usually useful after a filter or other operation that returns a sufficiently small subset of the data.
count()	Return the number of elements in the dataset.
first()	Return the first element of the dataset (similar to take(1)).
take(n)	Return an array with the first $n$ elements of the dataset.
takeSample(withReplacement, num, [seed])	Return an array with a random sample of <i>num</i> elements of the dataset, with or without replacement, optionally pre-specifying a random number generator seed.
takeOrdered(n, [ordering])	Return the first $n$ elements of the RDD using either their natural order or a custom comparator.
save As Text File (path)	Write the elements of the dataset as a text file (or set of text files) in a given directory in the local filesystem, HDFS or any other Hadoop-supported file system. Spark will call toString on each element to convert it to a line of text in the file.
saveAsSequenceFile(path) (Java and Scala)	Write the elements of the dataset as a Hadoop SequenceFile in a given path in the local filesystem, HDFS or any other Hadoop-supported file system. This is available on RDDs of key-value pairs that implement Hadoop's Writable interface. In Scala, it is also available on types that are implicitly convertible to Writable (Spark includes conversions for basic types like Int, Double, String, etc).
saveAsObjectFile(path) Java and Scala)	Write the elements of the dataset in a simple format using Java serialization, which can then be loaded using SparkContext.objectFile().

# Criando dados para "brincar"

#### Criar um arquivo de entrada:

- > cd ~
- > gedit alunos.csv

#### Iniciar o spark shell

> pyspark

```
Nome, Idade
John, 23
Jim, 22
Emily, 41
Nina, 50
Susan, 31
```

#### Brincando com os dados

- alunos = sc.textFile("file:///home/posgrad/alunos.csv")
- alunos.take(2)
- alunosComJ = alunos.filter(lambda row: 'J' in row)
- alunosComJ.take(2)
- nums = sc.parallelize([1, 2, 3, 4])
- numsMaisUm = nums.map(lambda x: x+1)
- nums2 = sc.parallelize([4, 5, 6])
- nums.union(nums2).take(10)
- nums.intersection(nums2).take(10)
- exit()

# Spark

Rodando script Python

## WordCount em Spark

#### 1. Download dos dados e do script no Terminal

```
> cd ~
> wget
https://raw.githubusercontent.com/felipetimbo/streaming-data-course/main/shakespeare.txt
```

> wget https://raw.githubusercontent.com/felipetimbo/streaming-data-course/main/wordcount.py

#### 2. Abrir o script no VSCode

> code wordcount.py

#### 3. Rodar no terminal o script utilizando Spark:

> /opt/spark/bin/spark-submit wordcount.py

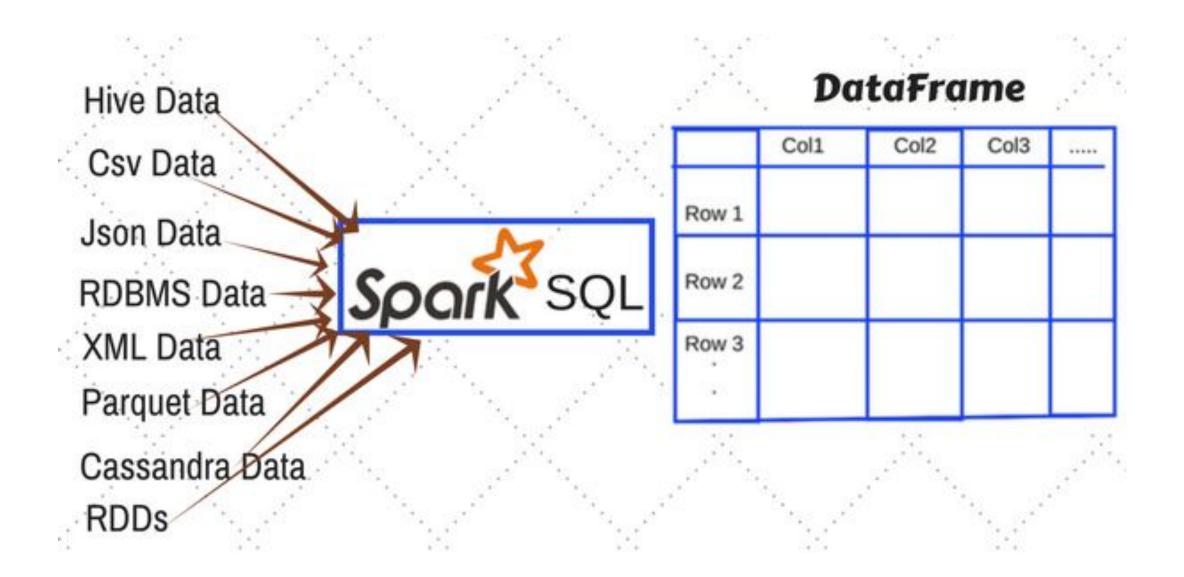
### Exercício

Ordenar pelas palavras que mais aparecem no livro de Shakespeare.

# Spark - Dataframes

### Spark - Dataframes

- Extensão do RDD
- Pode rodar consultas SQL
- Possui um esquema (maneira melhor de lidar)



### Dataframes - Exemplo

#### Em outro terminal, baixar o conjunto de dados de pessoas

```
wget
https://raw.githubusercontent.com/felipetimbo/streaming-dat
a-course/main/people.json
```

### Dataframes - Exemplo

Criando um dataframe de pessoas no terminal Pyspark

```
>> df = spark.read.json("file:///home/posgrad/people.json")
```

### Brincando com Dataframes

```
\rightarrow df.show()
> df.printSchema()
> df.select(df.age).show()
\rightarrow df.select(df['name'], df['age'] + 1).show()
>> df.filter(df['age'] > 21).show()
> df.groupBy("age").count().show()
\gg df.orderBy("age", ascending = False).take(2)
\triangleright newrow = spark.createDataFrame([(16, 'Karlos')], df.columns)
> newdf = df.union(newrow)
> newdf.createOrReplaceTempView("pessoas")
> spark.sql("SELECT * FROM pessoas").show()
```

### Por fim...

Para finalizar o serviço do Spark, basta executar os comandos:

- > stop-worker.sh
- > stop-master.sh

# Dúvidas